Instituto Superior
de Engenharia
Politécnico de Coimbra

DEPARTAMENTO DE ENGENHARIA INFORMÁTICA E SISTEMAS

Deteção De Fraude Em Comunicações De Voz Usando Técnicas De Machine Learning

Engenharia Informática

Autor

Dinis Alexandre Rodrigues Gonçalves

Orientador

Simão Pedro Mendes Cruz Reis Paredes

Co-Orientadores

João Carlos Costa Faria da Cunha

Coimbra, julho 2026

INSTITUTO POLITÉCNICO
DE COIMBRA

INSTITUTO SUPERIOR
DE ENGENHARIA
DE COIMBRA

Resumo

A deteção de fraude em comunicações de voz constitui um desafio relevante no setor das telecomunicações, devido à evolução constante das estratégias utilizadas por atacantes e à dificuldade de analisar manualmente grandes volumes de chamadas. Neste contexto, técnicas de *Machine Learning*, *Deep Learning* e *Natural Language Processing* têm vindo a ganhar importância, permitindo explorar automaticamente padrões linguísticos presentes em transcrições de chamadas e diálogos.

O presente trabalho teve como objetivo estudar e avaliar a aplicação de arquiteturas de *Deep Learning* à deteção de fraude em comunicações de voz, recorrendo à análise textual de transcrições e datasets conversacionais. A metodologia seguida incluiu a análise dos datasets, o pré-processamento dos textos, a normalização de identificadores dos intervenientes, a criação de vocabulário, a conversão dos textos em sequências numéricas, a utilização de camadas de *embedding* e a divisão dos dados em conjuntos de treino, validação e teste. A avaliação foi realizada com recurso a métricas como *accuracy*, *precision*, *recall* e *F1-score*. Para além da avaliação individual em cada dataset, foi também realizada uma análise de generalização entre diferentes conjuntos de dados.

Os resultados obtidos demonstraram que os modelos avaliados foram capazes de atingir desempenhos elevados na tarefa de classificação, tanto em datasets sintéticos como em datasets reais. No entanto, verificou-se que os resultados em datasets sintéticos devem ser interpretados com cautela, uma vez que estes apresentam estruturas mais regulares e padrões linguísticos mais controlados. A análise de generalização mostrou ainda que um bom desempenho num determinado dataset não garante necessariamente robustez quando o modelo é aplicado a dados com características diferentes.

Em suma, o trabalho desenvolvido permitiu demonstrar o potencial de arquiteturas de *Deep Learning* na deteção de fraude a partir de transcrições de chamadas. Contudo, a aplicação prática destas abordagens exige validação adicional com dados reais mais diversificados, maior controlo sobre a qualidade das transcrições e, idealmente, integração com outras fontes de informação, como metadados ou características acústicas.

Palavras-chave: deteção de fraude, transcrições de chamadas, *Deep Learning*, classificação textual

Abstract

Fraud detection in voice communications is a relevant challenge in the telecommunications sector, due to the constant evolution of the strategies used by attackers and the difficulty of manually analysing large volumes of calls. In this context, *Machine Learning*, *Deep Learning* and *Natural Language Processing* techniques have become increasingly important, allowing the automatic exploration of linguistic patterns present in call transcripts and dialogues.

This work aimed to study and evaluate the application of *Deep Learning* architectures to fraud detection in voice communications, using textual analysis of transcripts and conversational datasets. The adopted methodology included dataset analysis, text preprocessing, normalization of speaker identifiers, vocabulary creation, conversion of texts into numerical sequences, use of *embedding* layers and data splitting into training, validation and test sets. The evaluation was carried out using metrics such as *accuracy*, *precision*, *recall* and *F1-score*. In addition to the individual evaluation on each dataset, a generalization analysis across different datasets was also performed.

The results obtained showed that the evaluated models were able to achieve high performance in the classification task, both on synthetic datasets and on real datasets. However, the results obtained on synthetic datasets must be interpreted with caution, since these datasets present more regular structures and more controlled linguistic patterns. The generalization analysis also showed that good performance on a specific dataset does not necessarily guarantee robustness when the model is applied to data with different characteristics.

In summary, the work developed demonstrated the potential of *Deep Learning* architectures for fraud detection based on call transcripts. However, the practical application of these approaches requires further validation with more diverse real-world data, greater control over transcript quality and, ideally, integration with other sources of information, such as metadata or acoustic features.

Keywords: fraud detection, call transcripts, *Deep Learning*, text classification.

Epígrafe

"To men of science like us, perfection is a dead end, a condition of hopelessness! Always strive to be better than anything that came before you, but not perfect."

(Mayuri Kurotsuchi, in Bleach, de Tite Kubo, 2001)

Agradecimentos

Em primeiro lugar, gostaria de agradecer à minha família, pelo apoio constante ao longo de todo o meu percurso académico, em especial aos meus pais. A sua presença, compreensão e incentivo foram fundamentais nos momentos mais exigentes, permitindo-me manter a motivação e a confiança necessárias para concluir esta etapa.

Agradeço também aos meus colegas que desenvolveram projetos em paralelo comigo, pela partilha de ideias, dúvidas, dificuldades e soluções ao longo do trabalho. A colaboração e discussão conjunta foram importantes não só para o desenvolvimento técnico do projeto, mas também para tornar este percurso mais enriquecedor.

Quero ainda agradecer aos professores e orientadores que acompanharam este trabalho, pelo apoio, pelos materiais disponibilizados, pelas sugestões e pela orientação prestada ao longo das diferentes fases do projeto. O seu contributo foi essencial para estruturar o trabalho, clarificar decisões metodológicas e melhorar a qualidade do relatório.

Por fim, agradeço à WIT Software e a todos os elementos da empresa que, de alguma forma, contribuíram para a realização deste projeto. A oportunidade de desenvolver este trabalho em contacto com um contexto empresarial real foi muito importante para a minha aprendizagem, permitindo aplicar conhecimentos adquiridos ao longo do curso e compreender melhor a sua relevância prática.

A todos, o meu sincero obrigado.

Trabalho parcialmente desenvolvido no âmbito do projeto n.º 24349 "AI4NextGen - Plataforma de Generative AI para a próxima geração das Comunicações Móveis", com o código de operação COMPETE2030-FEDER-02965700, do Instituto Politécnico de Coimbra, financiado nos termos do Aviso MPr-2025-4 - SIID - ID Empresarial - Operações Individuais ou em Copromoção, com o apoio financeiro do Fundo Europeu de Desenvolvimento Regional (FEDER), através do Programa Temático Inovação e Transição Digital (COMPETE 2030), do Portugal 2030 e pela União Europeia.

Índice

Resumo i

Abstract ii

Epígrafe iii

Agradecimentos iv

Índice v

Índice de tabelas viii

Índice de figuras ix

Lista de abreviaturas ix

1 Introdução 1
1.1 Motivação 2
1.2 Entidade de Acolhimento 2
1.3 Instituto Superior de Engenharia de Coimbra 3
1.4 Enquadramento 4
1.4.1 Enquadramento Europeu 4
1.5 Objetivos e Plano de Trabalho 5
1.6 Estrutura do Relatório 6

2 Estado da Arte 7
2.1 Introdução ao Problema 7
2.2 Fraude em Telecomunicações 8
2.2.1 Tipos de Fraude 8
2.2.2 Impacto e Principais Desafios na Fraude 11
2.3 O Combate Tradicional à Fraude 11
2.3.1 Autenticação de Chamadas e STIR/SHAKEN 12
2.3.2 Limitações das Abordagens Tradicionais 13
2.4 Abordagens Clássicas de *Machine Learning* 13
2.4.1 Limitações das Abordagens Clássicas 14

2.5 *Deep Learning* Aplicado à Fraude . . . 14
2.5.1 *Multi-Layer Perceptrons* . . . 15
2.5.2 *Convolutional Neural Networks* . . . 16
2.5.3 *Recurrent Neural Networks* . . . 17
2.6 *Natural Language Processing* e *Transformers* . . . 17
2.6.1 Transcrição Automática de Chamadas de Voz . . . 18
2.6.2 *Embeddings* e Representação Textual . . . 19
2.6.3 Modelos *Transformer* . . . 20
2.7 Desafios Atuais . . . 21
2.8 Comparação entre Abordagens . . . 22
2.9 Síntese Crítica . . . 22

3 Metodologias . . . 24
3.1 Visão Geral . . . 24
3.2 Datasets . . . 26
3.2.1 Datasets da Fase Exploratória . . . 26
3.2.2 Datasets da Fase de Especialização . . . 27
3.3 Análise Exploratória dos Dados (EDA) . . . 29
3.4 Pré-Processamento . . . 30
3.5 Representação Textual . . . 32
3.6 Estratégia Experimental . . . 33
3.7 Métricas de Avaliação . . . 35
3.8 Ferramentas Utilizadas . . . 37

4 Trabalho Realizado/Implementação . . . 39
4.1 Fase Exploratória . . . 39
4.2 Implementação da Abordagem de Deep Learning . . . 39
4.3 Modelos Desenvolvidos . . . 41
4.3.1 O Modelo Base . . . 41
4.3.2 LSTM e GRU . . . 42
4.3.3 Bi-LSTM e Bi-GRU . . . 43
4.3.4 Convolutional Neural Networks . . . 44
4.4 Configuração Experimental . . . 46

5 Resultados e Discussão . . . 49
5.1 Resultados da Fase de Especialização . . . 49
5.2 Análise de Generalização entre Datasets . . . 54
5.3 Discussão dos Resultados . . . 57
5.4 Limitações . . . 59

6 Conclusão . . . 61

Referências bibliográficas 63

Anexos 67
Anexo A - Proposta de Projeto 67

Índice de tabelas

1.1 Escalonamento das tarefas a realizar. 5

2.1 Comparação das diferentes Arquiteturas 22

3.1 Resumo dos datasets utilizados na fase de especialização. 28
3.2 Ferramentas e bibliotecas utilizadas no desenvolvimento do projeto. . . . 37

4.1 Excerto da tabela relativa ao Dataset *TeleAntiFraud* 40
4.2 Resumo das arquiteturas implementadas 46
4.3 Principais hiperparâmetros utilizados nas experiências. 48

5.1 Resultados no dataset *Multi Agent Scam Conversation* (MASC). 50
5.2 Resultados no dataset *Single Agent Scam Conversation* (SASC). 50
5.3 Resultados no dataset *Scammer Conversation* (SSC). 51
5.4 Resultados no dataset *Scam Dialogue* (SSD). 51
5.5 Resultados no dataset TeleAntiFraud. 53

Índice de figuras

1.1 Logótipo da WIT Software. 3
1.2 Logótipo do ISEC 3
1.3 Logótipo do Compete 2030. 4

2.1 Pipeline de Fraud Detection 8
2.2 *Wangiri Fraud Scheme* 10
2.3 A Arquitetura MLP 15
2.4 A arquitetura Transformer 20

3.1 Pipeline do fluxo de trabalho 25
3.2 O processo de Tokenização 30
3.3 A criação do Vocabulário 32

4.1 Arquitetura do Modelo Base 42
4.2 Arquitetura dos Modelos LSTM e GRU 43
4.3 Arquitetura dos Modelos LSTM e GRU Bidirecionais 44
4.4 Arquitetura dos Modelos CNN para texto 45

5.1 Resumo visual das métricas nos Datasets Sintéticos 52
5.2 Capacidade de generalização Bi-LSTM (*F1-score*). 55
5.3 Capacidade de generalização Bi-LSTM (*recall*). 55
5.4 Capacidade de generalização CNN (*F1-score*). 56
5.5 Capacidade de generalização CNN (*recall*). 56

Lista de abreviaturas

ASR	*Automatic Speech Recognition*
BERT	*Bidirectional Encoder Representations from Transformers*
CDR	*Call Details Record*
CNN	*Convolutional Neural Network*
CSV	*Comma-Separated Values*
DEIS	Departamento de Engenharia Informática e Sistemas
EDA	*Exploratory Data Analysis*
GRU	*Gated Recurrent Unit*
IDE	*Integrated Development Environment*
IEEE	*Institute of Electrical and Electronics Engineers*
IMDb	*Internet Movie Database*
IPC	Instituto Politécnico de Coimbra
ISEC	Instituto Superior de Engenharia de Coimbra
LSTM	*Long-Short Term Memory*
MLP	*Multi Layer Perceptron*
NLP	*Natural Language Processing*
OOV	*Out-of-Vocabulary*
RNN	*Recurrent Neural Network*
SHAKEN	*Signature-based Handling of Asserted Information Using tokens*
STIR	*Secure Telephone Identity Revisited*
SVM	*Support Vector Machine*
UK	*United Kingdom*
UX	*User Experience*

1 Introdução

A deteção de fraudes tem-se tornado uma área crítica em diversos setores, nomeadamente no setor das telecomunicações, devido ao aumento da complexidade e sofisticação das atividades fraudulentas. Nos últimos anos, técnicas de Processamento de Linguagem Natural (NLP) e *Deep Learning* têm mostrado grande potencial na análise automática de grandes volumes de dados textuais e de áudio, permitindo identificar padrões e anomalias que seriam difíceis de detetar manualmente [1].

O presente relatório insere-se no âmbito de um projeto de colaboração entre o DEIS ISEC e a empresa WIT Software. Visa precisamente a familiarização com técnicas de *Machine Learning*, com o objetivo de estudar o estado da arte e aplicar os conhecimentos adquiridos na deteção de fraudes a partir de transcrições de chamadas telefónicas. A primeira fase consiste num estudo exploratório, incluindo a implementação de modelos clássicos de NLP, *Transformers*, análise de *embeddings*, diferentes técnicas de pré-processamento de texto e criação/avaliação de modelos em *datasets* de referência.

Na fase subsequente, pretende-se replicar e adaptar as técnicas adquiridas para o contexto específico da deteção de fraudes, explorando a utilização de redes neuronais recorrentes (RNN), redes neuronais convolucionais (CNN) e outras arquiteturas avançadas para extrair padrões relevantes de linguagem e comportamento presentes nas conversas telefónicas. Este trabalho pretende não só a aplicação prática das técnicas estudadas, mas também a avaliação do seu desempenho e limitações neste domínio específico de forma a contribuir para o desenvolvimento de soluções eficazes para a deteção de fraude em telecomunicações.

1.1 Motivação

A crescente digitalização dos serviços de telecomunicações tem sido acompanhada por um aumento significativo das tentativas de fraude através de chamadas telefónicas. A deteção precoce destas atividades torna-se, portanto, essencial para minimizar prejuízos financeiros e proteger a confiança dos utilizadores nos serviços.

Contudo, a identificação manual de comportamentos fraudulentos em chamadas de voz é uma tarefa morosa e pouco escalável, especialmente tendo em conta o elevado volume de comunicações processadas diariamente. Neste contexto, técnicas de *Machine Learning* e Processamento de Linguagem Natural surgem como soluções promissoras, permitindo analisar automaticamente transcrições de chamadas e identificar padrões linguísticos associados a comportamentos suspeitos.

Este projeto é um projeto final de licenciatura. Contudo, a motivação vai além do contexto académico, prendendo-se com a necessidade de desenvolver métodos automáticos e eficazes para a deteção de fraude em chamadas telefónicas, explorando o potencial de modelos avançados de *Deep Learning*.

O projeto pode apresentar relevância prática para a indústria das telecomunicações, contribuindo para o desenvolvimento de ferramentas que aumentem a segurança e eficiência na identificação de atividades fraudulentas. Paralelamente, permite o desenvolvimento de competências na área do *Machine Learning*, com potencial de aplicação em projetos futuros.

1.2 Entidade de Acolhimento

A WIT Software S.A., logótipo na figura 1.1, é uma empresa privada com mais de 25 anos de experiência em produtos e soluções na área das telecomunicações.

Sediada em Portugal, possui escritórios no *UK* e Japão e conta com mais de 200 engenheiros especializados na área das telecomunicações. O desenvolvimento de soluções para as grandes operadoras da área é um grande foco, trabalhando com parceiros em mais de 40 países, entidades como a *Vodafone*, *Deutsche Telekom*, *Swisscom*, *Safaricom* entre outros.

O escritório onde o trabalho foi realizado encontra-se situado no Centro de Empresas de Taveiro, Estrada de Condeixa, 3045-508 Taveiro.



Figura 1.1: Logótipo da WIT Software.

1.3 Instituto Superior de Engenharia de Coimbra

O Instituto Superior de Engenharia de Coimbra (ISEC), logótipo apresentado na figura 1.2, é uma unidade orgânica de ensino e investigação integrada no Instituto Politécnico de Coimbra (IPC), situada na Rua Pedro Nunes – Quinta da Nora, 3030-199 Coimbra.

Fundado em 1974, o ISEC destaca-se pela formação nas áreas da engenharia e tecnologia, promovendo uma forte ligação entre o meio académico e o tecido empresarial.

O Departamento de Engenharia Informática e de Sistemas (DEIS) é responsável pela formação na área da Engenharia Informática, desenvolvendo atividades de ensino, investigação e colaboração com empresas e instituições. O DEIS tem participado em diversos projetos tecnológicos e científicos, contribuindo para a aproximação entre a investigação académica e a aplicação prática em contexto empresarial.

No contexto deste projeto, o ISEC, através do DEIS, assegura o acompanhamento científico e pedagógico do trabalho desenvolvido, prestando apoio na definição das metodologias, análise dos resultados e enquadramento académico das tecnologias estudadas.



Figura 1.2: Logótipo do ISEC

1.4 Enquadramento

O projeto foi desenvolvido em paralelo por três elementos, partilhando uma fase inicial comum de estudo, experimentação e validação de técnicas de aprendizagem automática. Após esta fase, cada elemento aprofundou uma vertente específica: Machine Learning clássico, modelos Transformer e arquiteturas de Deep Learning.

O presente relatório centra-se nesta última vertente, explorando a aplicação de modelos neuronais à deteção de fraude em comunicações de voz.

Este projeto foi realizado como projeto/estágio final da Licenciatura de Engenharia Informática no ISEC. É realizado numa estreita colaboração entre o DEIS ISEC e a empresa WIT Software. Decorre em regime laboral híbrido, sendo que às segundas e quartas o trabalho é realizado nas estruturas da empresa em Taveiro, e às sextas nas estruturas do DEIS. Os restantes dias da semana foram dedicados ao trabalho remoto.

1.4.1 Enquadramento Europeu

O projeto realiza-se também no âmbito de um financiamento do programa europeu COMPETE 2030 (logótipo na figura 1.3). Este tem vários objetivos, para o âmbito deste projeto destaca-se o seguinte:

- *Apoiar o investimento na investigação e inovação, na digitalização, na competitividade e internacionalização das empresas, nas competências para a especialização inteligente e na transição industrial.*

Figura 1.3: Logótipo do Compete 2030.

1.5 Objetivos e Plano de Trabalho

Os principais objetivos do projeto foram delineados de forma a garantir um desenvolvimento eficaz e alinhado com as necessidades da WIT e com os objetivos académicos do ISEC. Podendo resumir-se nos seguintes objetivos:

1. Compreensão dos mecanismos de fraude em chamadas de voz
2. Estudo de técnicas utilizadas na deteção de fraude em chamadas de voz
3. Implementação e teste de métodos de ML para a deteção de fraude em chamadas de voz

Para atingir estes objetivos, o plano de trabalho foi realizado nas seguintes etapas:

1. **Estado da Arte**: Revisão de literatura e abordagens na área da deteção de fraude em chamadas de voz.
2. **Identificação de Recursos**: Identificação de conjuntos de dados e de métodos inteligentes que possam ser usados na deteção de fraude em chamadas de voz.
3. **Proposta de Abordagens**: Desenvolvimento de métodos inteligentes para deteção de fraude em chamadas de voz
4. **Validação**: Avaliação da eficácia comparativa das abordagens desenvolvidas.
5. **Documentação**: Elaboração do relatório final e preparação para a defesa.

Estes objetivos serão abordados de acordo com a sequência de etapas apresentada na tabela 1.1

Tabela 1.1: Escalonamento das tarefas a realizar.

Tarefas		**Meses**									
		N		N+1		N+2		N+3		N+4	
T1	*Estado da Arte*										
T2	*Identificação de Recursos*										
T3	*Desenvolvimento*										
T4	*Validação*										
T5	*Documentação*										

1.6 Estrutura do Relatório

- **Capítulo 2 - Estado da Arte**

  Este capítulo apresenta os principais conceitos relacionados com fraude em telecomunicações, abordagens tradicionais de deteção, técnicas de *Machine Learning*, *Deep Learning*, NLP e *Transformers*, bem como os principais desafios associados ao domínio das chamadas de voz.

- **Capítulo 3 - Metodologias**

  Este capítulo descreve a metodologia adotada no desenvolvimento do trabalho, incluindo a organização do projeto em fase exploratória e fase de especialização, os datasets considerados, os procedimentos de pré-processamento, a estratégia experimental, as ferramentas utilizadas e as métricas de avaliação.

- **Capítulo 4 - Trabalho Realizado e Implementação**

  Este capítulo apresenta o trabalho prático desenvolvido, com foco na implementação e treino de modelos de Deep Learning aplicados à classificação de comunicações ou transcrições potencialmente fraudulentas.

- **Capítulo 5 - Resultados e Discussão**

  Este capítulo apresenta os resultados obtidos, comparando o desempenho dos modelos implementados e discutindo as principais limitações observadas.

- **Capítulo 6 - Conclusão**

  Este capítulo reúne as conclusões do trabalho, as principais aprendizagens, limitações e possíveis direções de trabalho futuro.

2 Estado da Arte

Neste capítulo é apresentado o estado da arte relativo à deteção de fraude com recurso a técnicas de *Machine Learning*, *Deep Learning* e *Natural Language Processing*. São abordadas as principais abordagens existentes na literatura, os desafios associados ao problema e as tecnologias mais utilizadas atualmente em cenários de deteção de fraude em telecomunicações e análise de dados textuais.

2.1 Introdução ao Problema

A deteção de fraude constitui um problema amplamente estudado em diferentes setores, incluindo banca, seguros, comércio eletrónico e telecomunicações. O principal objetivo destes sistemas consiste na identificação automática de comportamentos suspeitos ou anómalos que possam indicar atividades fraudulentas.

Tradicionalmente, muitos sistemas de deteção de fraude baseavam-se em regras definidas manualmente e mecanismos estáticos de verificação. Contudo, o aumento do volume de dados e a constante evolução das estratégias utilizadas por atacantes tornaram estas abordagens insuficientes em muitos cenários reais [2].

Nos últimos anos, técnicas de *Machine Learning* têm sido amplamente exploradas para automatizar a deteção de padrões fraudulentos [3] [4], permitindo a análise de grandes quantidades de dados e a adaptação a comportamentos mais complexos. Mais recentemente, o crescimento das abordagens baseadas em *Deep Learning* [5] [6] e *Transformers* possibilitou avanços significativos na análise de dados sequenciais e textuais, especialmente em problemas relacionados com comunicações e linguagem natural. A figura 2.1 mostra de forma generalizada o processo do uso destas tecnologias para a deteção de fraude.

Apesar destes avanços, a deteção de fraude continua a apresentar vários desafios , como o desequilíbrio entre classes, a necessidade de processamento em tempo real e a constante adaptação dos atacantes para evitar os mecanismos de deteção existentes.

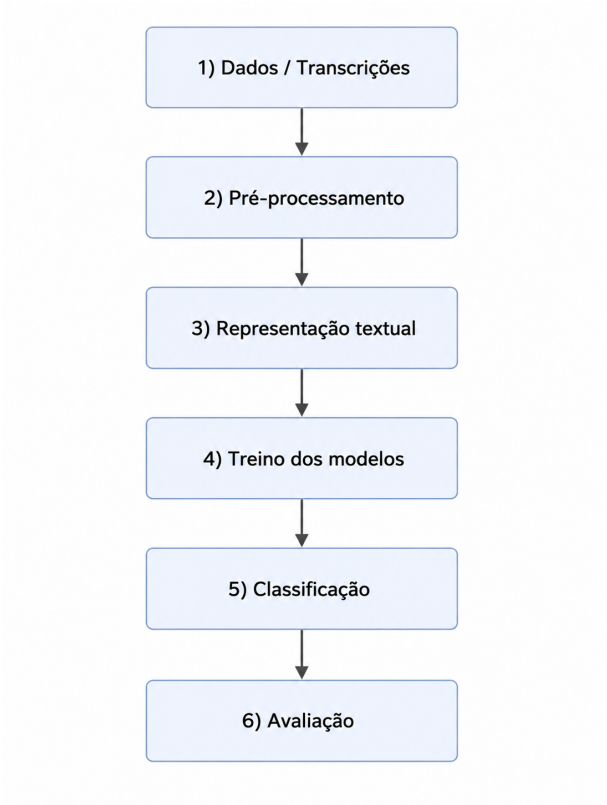


Figura 2.1: Pipeline de Fraud Detection

2.2 Fraude em Telecomunicações

A fraude em telecomunicações corresponde à utilização abusiva ou ilegítima de serviços de comunicação com o objetivo de obter benefícios financeiros ou acesso indevido a recursos. Este tipo de fraude representa atualmente um problema relevante para operadoras e prestadores de serviços, devido ao impacto económico e operacional associado.

Ao contrário de outros domínios de fraude, como o financeiro [7], onde predominam dados estruturados, a fraude em telecomunicações envolve frequentemente informação não estruturada, incluindo chamadas de voz, mensagens e transcrições textuais. Como consequência, a análise automática deste tipo de dados tornou-se um tema de investigação relevante na literatura recente.

2.2.1 Tipos de Fraude

A fraude em telecomunicações pode assumir diferentes formas, dependendo do objetivo do atacante, do tipo de serviço explorado e dos dados utilizados para executar o esquema fraudulento. Nesta secção são descritos alguns dos tipos de fraude mais relevantes no contexto das telecomunicações.

Fraude baseada em engenharia social

Explora mecanismos psicológicos como urgência, medo ou confiança para manipular a vítima e induzir ações específicas [8].

Ao contrário de ataques puramente técnicos, a engenharia social baseia-se na manipulação do comportamento humano. Os atacantes recorrem frequentemente a estratégias associadas a autoridade, escassez, recompensa ou pressão temporal para aumentar a probabilidade de sucesso. Este tipo de fraude apresenta particular relevância para sistemas de análise textual e processamento de linguagem natural, uma vez que muitos dos indicadores de fraude se encontram presentes no conteúdo linguístico das interações.

Subscription Fraud

Criação de contas ou contratos utilizando identidades falsas com o objetivo de obter serviços sem pagamento [9].

Este tipo de fraude ocorre frequentemente durante o processo de subscrição de serviços de telecomunicações. Os burlões utilizam documentos falsificados, identidades roubadas ou informações fraudulentas para obter cartões SIM, equipamentos ou contratos de serviço. As perdas associadas podem incluir custos operacionais, incumprimento contratual e utilização indevida da infraestrutura da operadora.

Fraude em roaming e abuso de serviços

Exploração de vulnerabilidades em sistemas de tarifação e autenticação de serviços móveis [10].

Os ataques de *roaming fraud* aproveitam frequentemente atrasos na comunicação entre operadores internacionais. Durante este intervalo, os burlões conseguem gerar elevados volumes de tráfego antes que sejam aplicados mecanismos de faturação ou bloqueio. Situações semelhantes podem ocorrer através da exploração indevida de serviços premium, encaminhamento de chamadas ou utilização abusiva de recursos disponibilizados pelas operadoras.

***Vishing* (*Voice Phishing*)**

O atacante faz-se passar por uma entidade legítima, como bancos, operadoras ou organismos governamentais, com o objetivo de obter informações confidenciais da vítima através de chamadas telefónicas.

O *vishing* constitui atualmente uma das formas mais comuns de fraude telefónica [11]. Estes ataques recorrem frequentemente a técnicas de engenharia social, explorando sentimentos de urgência, medo ou confiança para induzir a vítima a revelar creden-

ciais de acesso, dados bancários ou informações pessoais. O aumento da utilização de sistemas automáticos de chamadas e tecnologias de síntese de voz tem contribuído para a sofisticação deste tipo de fraude, tornando a sua deteção um desafio crescente.

Wangiri

Consiste em chamadas de curta duração provenientes de números internacionais desconhecidos, incentivando a vítima a retornar a chamada para números de custo elevado [12].

O termo *Wangiri*, de origem japonesa, significa aproximadamente "tocar e desligar". Neste esquema, os atacantes realizam milhares de chamadas automáticas para diferentes utilizadores, interrompendo a ligação antes de ser atendida. A curiosidade da vítima leva frequentemente ao retorno da chamada, gerando receitas através de números premium ou tarifas internacionais elevadas. Este tipo de fraude continua a representar perdas económicas significativas para operadores e consumidores.

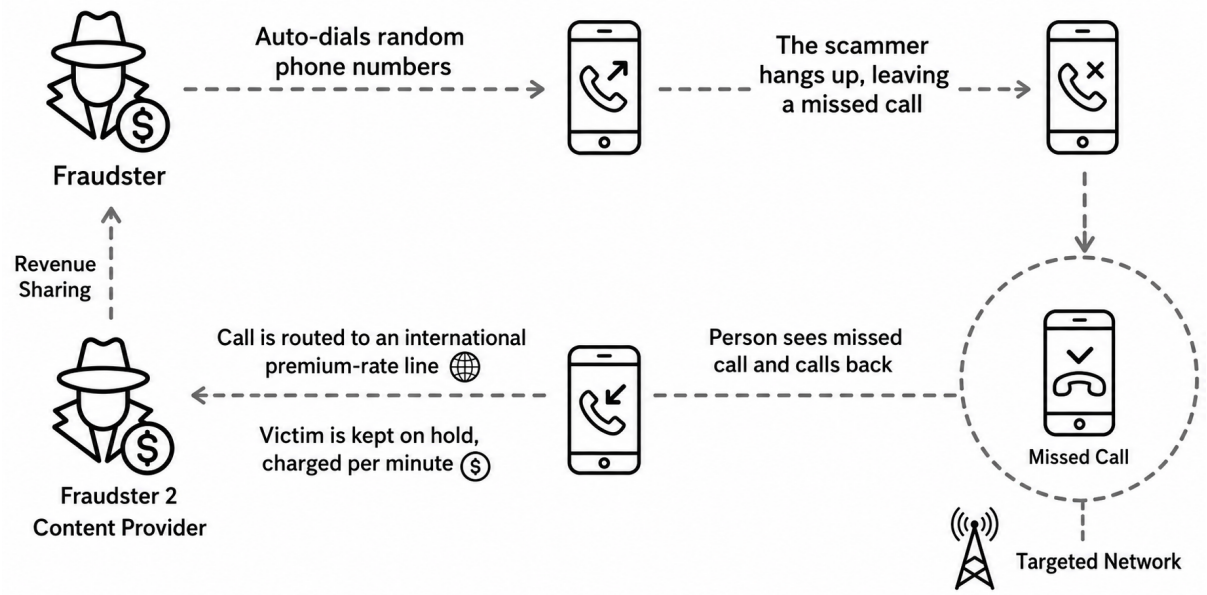


Figura 2.2: *Wangiri Fraud Scheme*

No contexto deste projeto, é importante distinguir fraudes detetáveis sobretudo através de padrões de tráfego e metadados, como *Wangiri* ou *roaming fraud*, de fraudes em que o conteúdo da comunicação é determinante, como *vishing*, fraudes de suporte técnico e engenharia social. Dado o foco deste trabalho em transcrições de chamadas, a segunda categoria assume particular relevância.

2.2.2 Impacto e Principais Desafios na Fraude

A fraude em telecomunicações tem um impacto significativo tanto para operadores como para utilizadores finais. Para além das perdas financeiras diretas [11], este tipo de fraude contribui para a degradação da confiança nos serviços digitais e aumenta os custos operacionais associados a monitorização e segurança.

Nos últimos anos, o crescimento de ataques baseados em chamadas telefónicas e engenharia social motivou um aumento da investigação em técnicas automáticas de deteção de fraude, especialmente recorrendo a modelos de aprendizagem automática capazes de analisar padrões linguísticos e comportamentais.

A deteção de fraude apresenta desafios específicos que dificultam o desenvolvimento de sistemas eficazes. Um dos principais problemas é a elevada variabilidade dos padrões fraudulentos, uma vez que os atacantes alteram constantemente os seus comportamentos para evitar mecanismos de deteção.

Além disso, os dados disponíveis são frequentemente heterogéneos, combinando informação estruturada, como *Call Detail Records* (CDR), com dados não estruturados, como transcrições de chamadas e mensagens textuais.

Outro desafio importante está relacionado com os requisitos de processamento em tempo real. Em muitos cenários, a deteção necessita de ocorrer durante ou imediatamente após a chamada, impondo restrições ao nível da latência e custo computacional dos modelos utilizados.

2.3 O Combate Tradicional à Fraude

Antes da adoção generalizada de técnicas de *Machine Learning*, a deteção de fraude era realizada principalmente através de sistemas baseados em regras e mecanismos de monitorização definidos por especialistas do domínio. Estas abordagens procuravam identificar comportamentos suspeitos através da análise de padrões previamente conhecidos, permitindo a geração automática de alertas sempre que determinadas condições fossem verificadas.

Os sistemas baseados em regras constituem uma das abordagens mais antigas utilizadas na deteção de fraude. Nestes sistemas, especialistas definem manualmente um conjunto de condições que caracterizam comportamentos potencialmente fraudulentos. Exemplos típicos incluem a deteção de volumes anormais de chamadas internacionais, múltiplas tentativas consecutivas de contacto para números específicos ou padrões de utilização incompatíveis com o perfil habitual do utilizador. Quando uma regra é ativada, o sistema pode gerar alertas, bloquear serviços ou encaminhar o caso para análise humana.

Outra abordagem amplamente utilizada consiste na manutenção de listas negras (*blac-*

klists) contendo números telefónicos, utilizadores ou entidades previamente identificados como fraudulentos. Sempre que uma comunicação envolve um elemento presente nestas listas, podem ser aplicadas medidas automáticas de mitigação, incluindo bloqueio de chamadas, limitação de serviços ou encaminhamento para sistemas adicionais de verificação. Embora simples de implementar, estas soluções apresentam limitações na deteção de novas ameaças ainda não catalogadas.

Os operadores de telecomunicações recorrem frequentemente a mecanismos de monitorização contínua para analisar padrões de utilização da rede. Através da observação de métricas como duração de chamadas, frequência de contactos, localização geográfica ou utilização de serviços específicos, é possível identificar comportamentos considerados anómalos. Estes sistemas desempenham um papel importante na deteção precoce de fraude, permitindo a identificação de eventos suspeitos antes da ocorrência de perdas significativas.

2.3.1 Autenticação de Chamadas e STIR/SHAKEN

Uma das abordagens mais recentes para a mitigação de fraude telefónica consiste na utilização de mecanismos de autenticação da identidade da chamada. Entre estes destaca-se o STIR/SHAKEN, desenvolvido para combater ataques de falsificação do identificador de chamadas (*Caller ID Spoofing*), nos quais o atacante manipula o número apresentado ao destinatário de forma a simular uma entidade legítima, como um banco, uma operadora ou um organismo governamental.

O STIR (*Secure Telephone Identity Revisited*) define um conjunto de mecanismos destinados a associar uma identidade verificável a chamadas telefónicas, recorrendo a assinaturas digitais e certificados. De forma geral, quando uma chamada é iniciada, o operador de origem pode assinar digitalmente informação associada à chamada, incluindo o número que liga. Esta informação é posteriormente transportada ou disponibilizada ao operador de destino, que pode validar a assinatura e verificar se a identidade apresentada é confiável [13].

O SHAKEN (*Signature-based Handling of Asserted Information Using toKENs*) corresponde ao enquadramento de implementação destes mecanismos em redes de voz baseadas em IP, nomeadamente através do protocolo SIP. Este modelo define a forma como os prestadores de serviços devem criar, transportar e validar as assinaturas associadas às chamadas, permitindo ao operador de destino avaliar o grau de confiança na identidade do chamador [14].

Na prática, o STIR/SHAKEN não bloqueia necessariamente uma chamada fraudulenta de forma automática, mas fornece informação adicional que pode ser utilizada por operadores, sistemas de filtragem ou dispositivos finais para classificar chamadas como verificadas, suspeitas ou potencialmente fraudulentas. Desta forma, torna-se mais di-

fícil para atacantes utilizarem números falsificados para aumentar a credibilidade de esquemas de fraude telefónica.

Apesar da sua relevância, esta abordagem apresenta limitações importantes. A sua eficácia depende da adoção por parte dos operadores envolvidos e da compatibilidade das redes utilizadas no encaminhamento da chamada. Além disso, atua principalmente ao nível da autenticação da identidade da chamada, não permitindo, por si só, determinar se o conteúdo da conversação é fraudulento. Assim, esquemas baseados em engenharia social, manipulação emocional ou pedidos de informação sensível podem continuar a ocorrer mesmo quando a identidade da chamada é tecnicamente autenticada.

Neste contexto, deve ser entendido como uma medida complementar aos sistemas de deteção de fraude. Embora contribua para reduzir ataques baseados em falsificação de identidade, não substitui abordagens capazes de analisar o conteúdo linguístico das interações. Esta limitação reforça a importância de técnicas de *Machine Learning*, *Deep Learning* e *Natural Language Processing* aplicadas à análise de chamadas e respetivas transcrições.

2.3.2 Limitações das Abordagens Tradicionais

Apesar da sua ampla utilização, os métodos tradicionais apresentam limitações significativas. A principal desvantagem reside na forte dependência de conhecimento especializado para definição e atualização das regras utilizadas.

Além disso, estas abordagens tendem a apresentar dificuldades na deteção de novos padrões de fraude, uma vez que os mecanismos de decisão dependem de comportamentos previamente conhecidos. A crescente complexidade dos ataques modernos e o aumento do volume de dados disponíveis motivaram, assim, a adoção de técnicas de *Machine Learning* capazes de aprender automaticamente padrões complexos e adaptar-se a novos cenários de fraude.

2.4 Abordagens Clássicas de *Machine Learning*

As primeiras abordagens de deteção de fraude baseadas em *Machine Learning* recorreram principalmente a modelos supervisionados tradicionais, aplicados sobretudo em conjuntos de dados estruturados.

Entre os modelos mais utilizados destacam-se a Regressão Logística [15], *Decision Trees*, *Random Forest*, *Support Vector Machines* (SVM) e métodos baseados em *Gradient Boosting*. Estes modelos demonstraram resultados relevantes em cenários financeiros e deteção de anomalias em dados tabulares.

Diversos trabalhos reportam que modelos como *Random Forest* apresentam boa capa-

cidade de generalização e robustez face a ruído, ou seja são modelos que possuem a capacidade de não perder performance quando confrontados com dados nunca antes vistos, sendo frequentemente utilizados em problemas com elevada dimensionalidade. Por outro lado, modelos SVM demonstram elevada precisão em determinados conjuntos de dados, embora possam apresentar limitações de escalabilidade em cenários de grande volume de informação. [16]

Apesar dos resultados positivos obtidos por estas abordagens, a literatura identifica várias limitações às quais é preciso dar atenção.

2.4.1 Limitações das Abordagens Clássicas

- **Dependência de *Feature Engineering*:** Os modelos clássicos dependem fortemente da definição manual de atributos relevantes, exigindo conhecimento especializado do domínio.
- **Dificuldade em modelar relações complexas:** Estas abordagens apresentam limitações na captura de padrões temporais, contextuais e relações não lineares complexas.
- **Sensibilidade ao desequilíbrio de classes:** Em muitos conjuntos de dados reais, os casos fraudulentos representam apenas uma pequena percentagem das observações. Desta forma os modelos correm o risco de não conseguirem aprender o que faz uma fraude, não sendo depois capazes de a identificar.
- **Baixa adaptabilidade:** Os modelos clássicos tendem a perder eficácia quando surgem padrões de fraude diferentes dos observados durante o treino, exigindo frequentemente reconfiguração, novo treino ou atualização manual das características utilizadas.
- **Limitações em dados não estruturados:** A aplicação destes modelos a texto, áudio ou sequências temporais complexas requer frequentemente etapas adicionais de transformação e representação dos dados.

Apesar destas limitações, os modelos clássicos continuam a ser utilizados em muitos sistemas reais devido à sua simplicidade, interpretabilidade e menor custo computacional [17].

2.5 *Deep Learning* Aplicado à Fraude

Na literatura recente, as abordagens baseadas em Deep Learning [18] têm demonstrado desempenho superior relativamente a modelos clássicos em tarefas envolvendo dados complexos, sequenciais e não estruturados.

O crescimento do volume e complexidade dos dados levou ao aumento da utilização de

técnicas de *Deep Learning* em problemas de deteção de fraude. Estas abordagens permitem aprender representações complexas diretamente a partir dos dados, reduzindo a dependência de *Feature Engineering* manual.

2.5.1 *Multi-Layer Perceptrons*

Os modelos *Multi-Layer Perceptron* (MLP) foram das primeiras arquiteturas de redes neuronais aplicadas à deteção de fraude. Estes modelos são compostos por uma camada de entrada, uma ou mais camadas escondidas e uma camada de saída, permitindo transformar os atributos fornecidos ao modelo em previsões de classificação.

Em cada camada, os neurónios combinam os valores recebidos da camada anterior através de pesos ajustáveis e aplicam uma função de ativação, o que permite ao modelo aprender relações não lineares entre os atributos. Esta característica torna os MLP mais expressivos do que modelos lineares, sendo úteis em cenários onde os padrões de fraude dependem da combinação de várias variáveis.

A figura 2.3 representa a arquitetura geral de um *Multi-Layer Perceptron*, evidenciando a passagem da informação desde a camada de entrada, através das camadas escondidas, até à camada de saída responsável pela classificação.

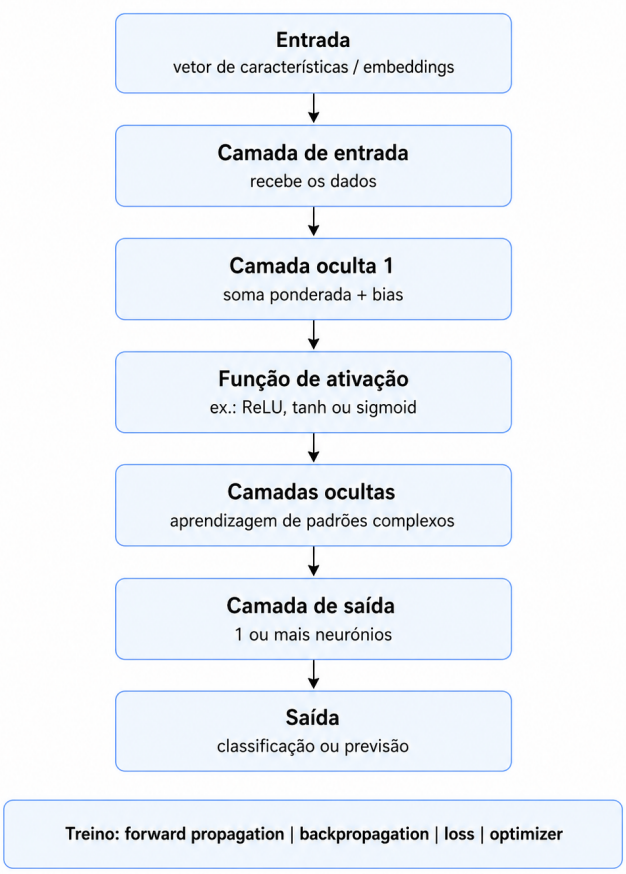


Figura 2.3: A Arquitetura MLP

No entanto, os MLP apresentam limitações na modelação de dependências temporais e sequenciais, uma vez que não possuem mecanismos para preservar a ordem dos dados ao longo do tempo. Por esse motivo, são geralmente mais adequados para dados tabulares estruturados do que para sequências textuais ou conversacionais complexas.

2.5.2 *Convolutional Neural Networks*

As *Convolutional Neural Networks* (CNN) têm sido utilizadas em tarefas de classificação de texto e deteção de padrões locais em sequências. Embora tenham sido inicialmente popularizadas em problemas de visão computacional, estas arquiteturas também podem ser aplicadas a dados textuais, permitindo identificar combinações de palavras, expressões ou padrões linguísticos relevantes para uma determinada tarefa.

Numa CNN aplicada a texto, a informação textual é normalmente representada através de vetores numéricos, como *embeddings*, sobre os quais são aplicados filtros convolucionais. Estes filtros percorrem pequenas janelas da sequência e procuram identificar padrões locais, como grupos de palavras ou expressões que possam estar associados a comportamentos suspeitos. Em problemas de fraude, isto pode incluir, por exemplo, expressões relacionadas com urgência, pedidos de dados sensíveis, referências a pagamentos ou tentativas de criação de confiança.

Após a aplicação das convoluções, é comum utilizar operações de *pooling*, que permitem reduzir a dimensionalidade da representação e manter as características mais relevantes detetadas pelos filtros. Desta forma, as CNN conseguem extrair automaticamente características úteis a partir do texto, reduzindo a necessidade de definição manual de atributos.

Diversos trabalhos recentes exploram CNN aplicadas à classificação de mensagens fraudulentas, deteção de *spam* e análise de transcrições de chamadas [19].

No entanto, apesar da sua eficácia na identificação de padrões locais, as CNN apresentam limitações na modelação de dependências de longo alcance, uma vez que analisam principalmente janelas limitadas da sequência. Por esse motivo, podem ter maior dificuldade em capturar relações contextuais distribuídas ao longo de conversações muito extensas.

2.5.3 *Recurrent Neural Networks*

As *Recurrent Neural Networks* (RNN) são arquiteturas concebidas para processar dados sequenciais, nos quais a ordem da informação é relevante. Ao contrário de modelos como os MLP, que tratam os atributos de entrada de forma independente, as RNN analisam a sequência elemento a elemento, mantendo um estado interno que permite preservar informação de passos anteriores. Esta característica torna as RNN particularmente úteis em problemas onde o contexto temporal ou sequencial influencia a decisão do modelo.

No entanto, as RNN tradicionais apresentam dificuldades em capturar dependências de longo prazo, uma vez que a informação relevante pode perder-se à medida que a sequência aumenta. Para mitigar este problema, surgiram variantes como as *Long Short-Term Memory* (LSTM) [20] e as *Gated Recurrent Units* (GRU). Estas arquiteturas introduzem mecanismos de controlo, designados por portas, que regulam a quantidade de informação a memorizar, atualizar ou descartar ao longo de uma sequência.

Desta forma, LSTM e GRU conseguem modelar relações temporais mais longas e analisar informação contextual ao longo do tempo, sendo frequentemente utilizadas em séries temporais financeiras, análise de comportamento e processamento de linguagem natural [21]. No contexto de transcrições de chamadas, estas arquiteturas podem ser úteis para capturar a evolução da conversa, identificando padrões que dependem da sequência de interações entre os interlocutores.

Apesar disto, os modelos recorrentes apresentam limitações associadas ao custo computacional e às dificuldades de paralelização durante o treino, uma vez que o processamento depende frequentemente da ordem sequencial dos dados. Além disso, em textos ou conversações muito extensas, podem continuar a apresentar dificuldades em preservar todo o contexto relevante.

2.6 *Natural Language Processing* e *Transformers*

A utilização de técnicas de *Natural Language Processing* tornou-se particularmente relevante em cenários de fraude envolvendo comunicação textual ou transcrições de chamadas telefónicas. No caso das chamadas de voz, esta análise depende frequentemente de uma etapa prévia de transcrição, na qual o sinal áudio é convertido em texto para posterior processamento.

Ao contrário das abordagens tradicionais baseadas exclusivamente em dados estruturados, os métodos de NLP permitem analisar o conteúdo semântico das comunicações, identificando intenções, padrões linguísticos e sinais de manipulação emocional.

2.6.1 Transcrição Automática de Chamadas de Voz

Em cenários de deteção de fraude em chamadas de voz, a aplicação de técnicas de NLP depende frequentemente de uma etapa prévia de transcrição automática de fala, também designada por *Automatic Speech Recognition* (ASR). Esta etapa consiste na conversão do sinal áudio de uma chamada numa representação textual, que pode posteriormente ser analisada por modelos de *Machine Learning* e *Deep Learning*.

No contexto da deteção de fraude, esta transformação é particularmente relevante, uma vez que muitos indicadores de comportamentos fraudulentos se encontram presentes no conteúdo linguístico da conversação. Exemplos destes indicadores incluem expressões de urgência, pedidos de informação sensível, referências a pagamentos, ameaças, simulação de autoridade ou tentativas de criação de confiança com a vítima.

Apesar da sua utilidade, a utilização de transcrições automáticas introduz desafios importantes. A qualidade da transcrição pode ser afetada por fatores como ruído de fundo, má qualidade da chamada, sotaques, velocidade da fala, interrupções, sobreposição de vozes e utilização de termos técnicos, nomes próprios ou sequências numéricas. Estes fatores podem originar erros de substituição, omissão ou inserção de palavras, alterando o conteúdo textual que será posteriormente analisado pelos modelos.

Este aspeto é especialmente relevante em tarefas de deteção de fraude, uma vez que pequenas alterações no texto podem influenciar a classificação final. A omissão de palavras associadas a valores monetários, credenciais, entidades bancárias ou expressões de pressão psicológica pode reduzir a capacidade do modelo em identificar padrões fraudulentos. Da mesma forma, erros de transcrição podem introduzir ruído nos dados e conduzir a falsos positivos ou falsos negativos.

Outro desafio associado às transcrições de chamadas prende-se com a estrutura da conversação. Em muitos casos, pode ser relevante distinguir o discurso dos diferentes interlocutores, identificar turnos de fala e preservar informação contextual ao longo da interação. Tarefas como a diarização de locutores, a pontuação automática e a segmentação da conversa podem, por isso, ter impacto na qualidade dos dados utilizados pelos modelos de NLP.

No âmbito deste trabalho, a transcrição deve ser entendida como uma representação intermédia da chamada de voz, e não como uma reprodução perfeita da comunicação original. Embora permita aplicar técnicas consolidadas de classificação textual, esta representação pode perder informação presente no sinal áudio, como entoação, pausas, hesitações ou alterações emocionais. Consequentemente, a avaliação de sistemas de deteção de fraude baseados em transcrições deve considerar não apenas o desempenho dos modelos de classificação, mas também as limitações associadas à qualidade e fiabilidade das transcrições utilizadas.

2.6.2 *Embeddings* e Representação Textual

A representação textual constitui uma etapa fundamental em tarefas de *Natural Language Processing*, uma vez que os modelos de aprendizagem automática não processam diretamente texto em linguagem natural. Assim, é necessário converter palavras, frases ou documentos em representações numéricas que possam ser utilizadas pelos algoritmos de classificação.

As primeiras abordagens de NLP aplicadas à deteção de fraude recorreram frequentemente a representações clássicas de texto, como *Bag-of-Words* e TF-IDF. No modelo *Bag-of-Words*, cada documento é representado através da frequência das palavras que nele ocorrem, ignorando a ordem dos termos e a estrutura gramatical da frase. Embora esta abordagem seja simples e eficiente, apresenta limitações na captura de contexto e significado semântico.

O TF-IDF (*Term Frequency-Inverse Document Frequency*) procura melhorar esta representação ao atribuir maior importância a termos que são frequentes num determinado documento, mas pouco comuns no conjunto total de documentos. Desta forma, palavras mais discriminativas recebem maior peso, enquanto termos muito frequentes e pouco informativos tendem a ter menor relevância. Esta técnica é útil em tarefas de classificação textual, incluindo deteção de *spam*, mensagens fraudulentas e análise de comunicações suspeitas.

Posteriormente, o desenvolvimento de modelos de *word embeddings*, como *Word2Vec* [22] e *GloVe* [23], permitiu representar palavras em espaços vetoriais contínuos e de menor dimensionalidade. Ao contrário das abordagens clássicas, estes modelos procuram capturar relações semânticas entre termos, fazendo com que palavras com significados ou contextos semelhantes fiquem próximas no espaço vetorial.

O *Word2Vec* aprende estas representações a partir do contexto em que as palavras aparecem, assumindo que palavras utilizadas em contextos semelhantes tendem a ter significados relacionados. Já o *GloVe* combina informação estatística global sobre a coocorrência de palavras num corpus, permitindo capturar relações semânticas a partir da frequência com que os termos surgem em conjunto.

Estas representações contribuíram significativamente para a melhoria do desempenho em tarefas de classificação textual relacionadas com fraude, *spam* e engenharia social, uma vez que permitem aos modelos explorar não apenas a presença de determinados termos, mas também relações de proximidade semântica entre palavras. No entanto, estes métodos apresentam ainda limitações na representação do contexto específico de cada ocorrência, uma vez que uma mesma palavra tende a possuir uma representação fixa independentemente da frase em que aparece.

2.6.3 Modelos *Transformer*

Mais recentemente, modelos baseados na arquitetura *Transformer*, introduzida por Vaswani et al. [24] passaram a dominar o estado da arte em diversas tarefas de NLP.

Modelos como *BERT* [25], ou variantes posteriores como *RoBERTa* [26] demonstraram elevada capacidade de generalização e compreensão contextual, sendo aplicados em tarefas de classificação textual, deteção de discurso malicioso e identificação de fraude em comunicações.

Uma das principais vantagens destes modelos reside no mecanismo de *self-attention*, que permite analisar relações contextuais entre palavras independentemente da distância na sequência.

A figura 2.4 apresenta a arquitetura geral de um *Transformer*, composta por um codificador (*encoder*) e um descodificador (*decoder*). O codificador recebe a sequência de entrada e transforma-a numa representação contextual através de camadas de *multi-head self-attention* e redes *feed-forward*. O descodificador utiliza essa representação, juntamente com a sequência de saída já gerada, para produzir a previsão seguinte. A figura evidencia ainda componentes importantes como o *positional encoding*, responsável por introduzir informação sobre a ordem dos elementos da sequência, e as ligações residuais com normalização, que contribuem para a estabilidade do treino.

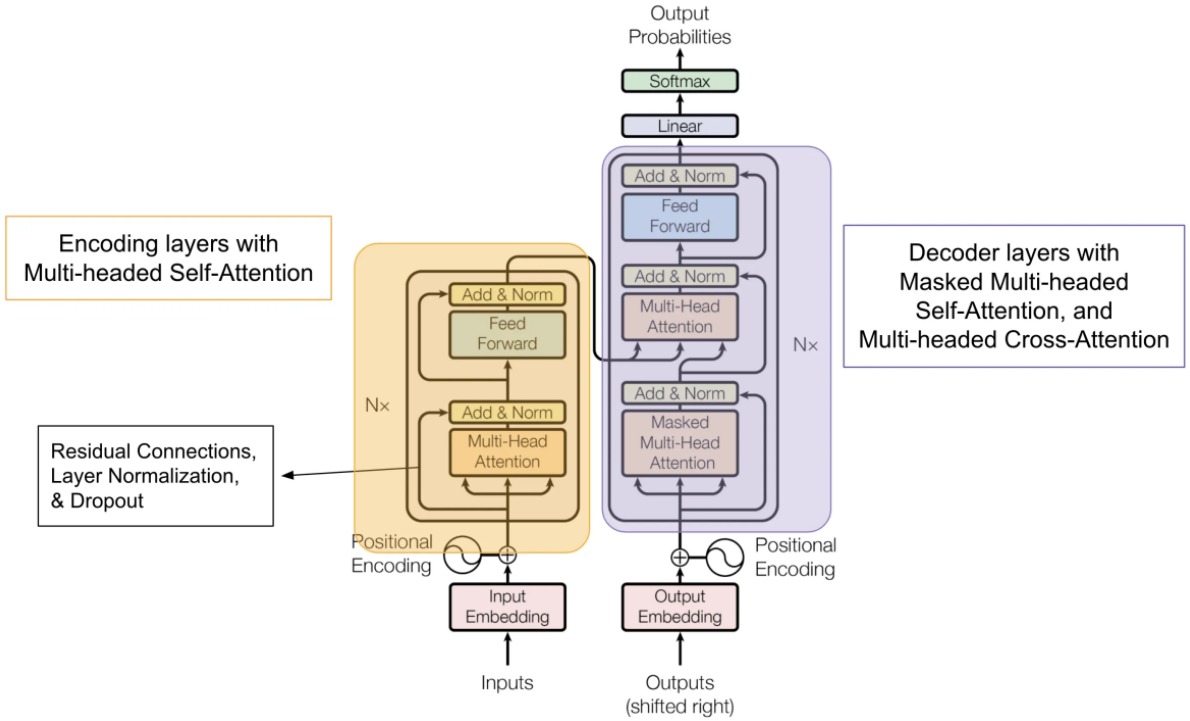


Figura 2.4: A arquitetura Transformer

Em problemas relacionados com fraude em chamadas telefónicas, estes modelos apresentam particular interesse devido à sua capacidade de capturar padrões linguísticos

subtis, sinais de manipulação emocional e estruturas conversacionais complexas.

Contudo, os modelos *Transformer* apresentam também limitações importantes, incluindo elevado custo computacional, necessidade de grandes volumes de dados e reduzida interpretabilidade.

2.7 Desafios Atuais

Apesar dos avanços observados nos últimos anos, a deteção de fraude continua a apresentar vários desafios relevantes na literatura. Estes desafios estão relacionados tanto com as características dos dados disponíveis como com a evolução constante dos comportamentos fraudulentos e com os requisitos práticos de implementação em sistemas reais.

- **Desequilíbrio de classes:** Os casos fraudulentos representam geralmente uma pequena percentagem dos dados disponíveis, conduzindo a problemas de desequilíbrio entre classes. Como consequência, muitos modelos tendem a favorecer a classe maioritária, reduzindo a capacidade de deteção dos casos de fraude.
- ***Concept drift*:** Os padrões de fraude encontram-se em constante evolução. As técnicas utilizadas por atacantes alteram-se frequentemente, fazendo com que modelos treinados com dados históricos possam perder eficácia caso não sejam atualizados regularmente.
- **Necessidade de processamento em tempo real:** Muitos sistemas reais necessitam de tomar decisões em tempo reduzido, exigindo modelos eficientes e infraestruturas capazes de processar grandes volumes de dados com baixa latência.
- **Interpretabilidade:** Em ambientes regulamentados, é frequentemente necessário justificar as decisões tomadas pelos modelos. No entanto, muitas arquiteturas de elevado desempenho funcionam como caixas negras, dificultando a explicação dos resultados obtidos.
- **Privacidade e segurança dos dados:** A utilização de dados sensíveis, como transcrições de chamadas ou informações pessoais, levanta preocupações relacionadas com privacidade, proteção de dados e conformidade regulamentar.

2.8 Comparação entre Abordagens

Existem várias abordagens, cada uma com vantagens e desvantagens relativamente às outras. A tabela 2.1 resume de forma simples os pontos fortes e as limitações das várias abordagens analisadas no decorrer do capítulo.

Tabela 2.1: Comparação das diferentes Arquiteturas

Abordagem	**Vantagens**	**Limitações**
Machine Learning Clássico	Baixo custo computacional; Fácil interpretabilidade	Necessita de *feature engineering*; dificuldade em relações complexas
CNN	Boa deteção de padrões locais	Limitações em dependências longas;
LSTM / GRU	Modelação sequencial e temporal	Treino lento e difícil paralelização
Transformers	Elevada compreensão contextual	Elevado custo computacional; Necessidade de grandes volumes de dados

2.9 Síntese Crítica

A literatura demonstra que as abordagens clássicas de *Machine Learning* continuam a apresentar vantagens ao nível da interpretabilidade e eficiência computacional, especialmente em cenários baseados em dados estruturados.

Contudo, a crescente complexidade dos padrões de fraude e o aumento da utilização de dados não estruturados motivaram a adoção de técnicas de *Deep Learning* e *Natural Language Processing*, capazes de capturar relações contextuais e padrões linguísticos mais complexos.

Os modelos baseados em arquiteturas *Transformer* destacam-se atualmente como uma das abordagens mais promissoras para tarefas de classificação textual e análise de comunicações, apresentando resultados superiores em diversos problemas relacionados com fraude e deteção de comportamentos maliciosos.

Apesar disso, persistem várias limitações importantes na literatura atual. Muitos trabalhos concentram-se em fraude financeira baseada em dados estruturados, existindo menos investigação focada especificamente em fraude em chamadas telefónicas e análise de transcrições conversacionais.

Além disso, diversos estudos recorrem a conjuntos de dados privados, dificultando a reprodução experimental e a comparação direta entre abordagens.

Neste contexto, torna-se relevante explorar arquiteturas capazes de analisar informação textual e sequencial em cenários de fraude telefónica, avaliando simultaneamente o

impacto de diferentes técnicas de pré-processamento, representação textual e modelos de *Deep Learning*.

Assim, o presente trabalho procura contribuir para o estudo e avaliação destas abordagens no contexto específico da deteção de fraude em transcrições de chamadas telefónicas.

3 Metodologias

Este capítulo apresenta a metodologia adotada no desenvolvimento do trabalho, descrevendo as principais etapas realizadas antes da implementação e avaliação dos modelos de deteção de fraude. São abordados os conjuntos de dados considerados, os procedimentos de pré-processamento aplicados às transcrições, a estratégia experimental seguida, as ferramentas utilizadas durante o desenvolvimento e as métricas usadas para avaliar o desempenho dos modelos.

A definição da metodologia assume particular importância neste projeto, uma vez que o desempenho de sistemas de deteção de fraude baseados em *Machine Learning* depende não apenas da escolha dos modelos, mas também da qualidade dos dados, da forma como estes são representados e das métricas utilizadas na avaliação. No contexto específico da análise de transcrições de chamadas telefónicas, aspetos como a limpeza textual, a normalização, a representação das palavras e o desequilíbrio entre classes podem ter um impacto significativo nos resultados obtidos.

3.1 Visão Geral

A metodologia adotada neste trabalho foi organizada em duas fases principais. A primeira fase teve um caráter exploratório e comum aos elementos envolvidos no projeto, tendo como objetivo a familiarização com técnicas de *Machine Learning*, *Deep Learning*, Processamento de Linguagem Natural e avaliação de modelos de classificação. Nesta fase foram utilizados datasets de referência, não necessariamente relacionados diretamente com o domínio da fraude em telecomunicações, mas úteis para validar *pipelines* de treino, pré-processamento, extração de características e avaliação experimental.

A segunda fase correspondeu à especialização individual do trabalho desenvolvido. Enquanto outras vertentes do projeto tiveram como único foco o uso de abordagens de *Machine Learning* Clássico e modelos *Transformer* para a deteção de fraude em chamadas, o presente relatório centra-se na aplicação de várias arquiteturas e modelos que englobam o universo do *Deep Learning*.

Importa salientar que, embora os modelos *Transformer* também pertençam ao domínio do *Deep Learning*, no contexto deste projeto estes foram tratados como uma vertente experimental separada, realizada por outro membro do projeto, e, sendo assim, não analisada no presente relatório. Assim sendo, a expressão *Deep Learning* é usada para se referir às arquiteturas CNN, RNN e RNNs bidirecionais, que foram trabalhadas,

enquanto outra vertente do projeto se dedicou especificamente ao estudo de modelos *Transformer*.

Esta organização permitiu, numa primeira etapa, adquirir e consolidar competências transversais em problemas de classificação supervisionada e, numa segunda etapa, aplicar essas competências ao domínio específico da deteção de fraude. Assim, os datasets utilizados ao longo do trabalho foram agrupados de acordo com a sua função: datasets exploratórios, usados para aprendizagem e validação inicial, e datasets da fase de especialização, usados para avaliar as abordagens propostas no contexto principal do projeto.

Considerando que o foco do projeto incide sobre a análise de transcrições, a figura 3.1 representa o processo metodológico. Este inicia-se com a seleção e preparação dos dados textuais, seguindo-se a aplicação de técnicas de pré-processamento, a transformação do texto em representações adequadas para os modelos e, por fim, a avaliação do desempenho obtido pelo modelo.

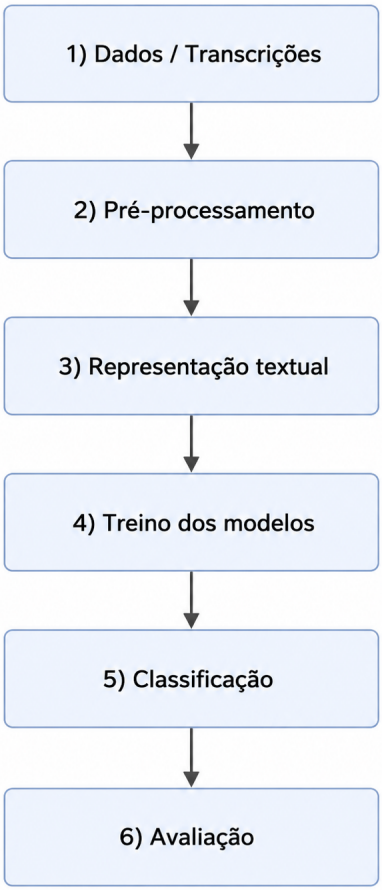


Figura 3.1: Pipeline do fluxo de trabalho

De forma geral, o processo pode ser dividido nas seguintes etapas: identificação dos conjuntos de dados relevantes, análise da sua estrutura, limpeza e normalização dos

textos, divisão dos dados em subconjuntos de treino e teste, extração ou geração de representações textuais, treino dos modelos e avaliação dos resultados através de métricas apropriadas.

Esta abordagem permite comparar diferentes técnicas de classificação, desde métodos mais simples e interpretáveis até arquiteturas mais complexas dentro do universo das arquiteturas de *Deep Learning*. A comparação entre estas abordagens é importante para compreender não apenas qual apresenta melhor desempenho, mas também quais os compromissos existentes entre precisão, custo computacional, interpretabilidade e capacidade de generalização.

3.2 Datasets

Tendo em conta a organização do projeto em duas fases, os datasets utilizados foram divididos em dois grupos principais. O primeiro grupo corresponde aos datasets da fase exploratória, utilizados para familiarização com tarefas de classificação, técnicas de pré-processamento, treino de modelos e análise de métricas. O segundo grupo corresponde aos datasets utilizados na fase de especialização, mais diretamente relacionados com o domínio da deteção de fraude, comunicações suspeitas ou análise textual de interações.

Esta distinção é importante, uma vez que nem todos os datasets utilizados ao longo do projeto tinham como objetivo representar diretamente o problema final da deteção de fraude em chamadas de voz. Alguns foram utilizados apenas como base de aprendizagem e validação técnica, enquanto outros serviram para avaliar as abordagens desenvolvidas no contexto principal do trabalho.

3.2.1 Datasets da Fase Exploratória

Na fase inicial do projeto foram utilizados datasets de referência com o objetivo de consolidar conhecimentos associados a tarefas de classificação, pré-processamento, representação de dados, treino de modelos e avaliação de desempenho. Estes datasets não tinham como objetivo representar diretamente o problema final da deteção de fraude em chamadas de voz, mas permitiram validar pipelines experimentais e desenvolver competências técnicas aplicáveis à fase seguinte do trabalho.

Um dos datasets utilizados nesta fase foi o dataset *Disaster Tweets*, composto por mensagens textuais classificadas de acordo com a sua relação com situações de desastre. Apesar de não estar diretamente relacionado com fraude em telecomunicações, este dataset revelou-se útil por envolver classificação de texto curto, permitindo testar técnicas de pré-processamento textual, tokenização, representação vetorial e modelos aplicados a dados não estruturados.

Foi também analisado um dataset de *Sentiment Analysis* do *IMDB*, utilizado para explorar tarefas de classificação textual em que o objetivo consiste em identificar a polaridade ou sentimento associado a *reviews* de filmes. Este tipo de dataset permitiu reforçar a familiarização com problemas de NLP, nomeadamente no tratamento de texto, representação de palavras e avaliação de modelos de classificação.

Por fim, foi considerado um dataset de classificação de vinhos, com características numéricas associadas a propriedades físico-químicas. Este dataset foi utilizado numa perspetiva introdutória, permitindo consolidar conceitos associados a classificação supervisionada, análise de atributos, normalização de dados e avaliação de desempenho. Por se tratar de dados tabulares e não textuais, a sua utilização teve um papel apenas exploratório, não sendo considerada na avaliação principal da abordagem proposta para deteção de fraude.

3.2.2 Datasets da Fase de Especialização

Na segunda fase do projeto foram considerados datasets mais próximos do domínio de aplicação pretendido, nomeadamente conjuntos de dados relacionados com comunicações fraudulentas, mensagens suspeitas, transcrições ou exemplos textuais associados a tentativas de engenharia social.

Devido à natureza sensível dos dados envolvidos em chamadas telefónicas reais, a disponibilidade de datasets públicos especificamente dedicados à deteção de fraude em transcrições de chamadas é limitada. Muitos dados utilizados em contexto industrial contêm informação pessoal, registos de comunicações ou conteúdo sensível, estando sujeitos a restrições legais e de privacidade.

Por este motivo, foram considerados datasets de referência relacionados com tarefas próximas do problema em estudo, permitindo avaliar a capacidade dos modelos de *Deep Learning* em identificar padrões textuais associados a comportamentos suspeitos ou fraudulentos. As características destes datasets estão resumidas na tabela 3.1, serviram assim como base para a avaliação principal da abordagem desenvolvida neste relatório.

Os datasets contêm exemplos rotulados, distinguindo entre comunicações legítimas e comunicações fraudulentas. Esta estrutura permite formular o problema como uma tarefa de classificação binária supervisionada, na qual o modelo aprende a associar padrões textuais a uma determinada classe.

A utilização destes datasets apresenta, contudo, algumas limitações. Em primeiro lugar, dados públicos podem não refletir totalmente a complexidade de chamadas telefónicas reais. Em segundo lugar, textos curtos, mensagens ou exemplos simulados, como é o caso de alguns dos datasets utilizados, podem não capturar todos os aspetos conversacionais presentes numa chamada de voz. Ainda assim, estes dados são úteis para

avaliar a viabilidade das abordagens propostas e para comparar diferentes técnicas de classificação textual num ambiente controlado.

Tabela 3.1: Resumo dos datasets utilizados na fase de especialização.

Dataset	**Tipo de Dados**	**N.º de instâncias**	**Classes**	**Sintético**	**Fonte**
Multi Agent Scam Conversation (MASC)	Diálogo em texto	1600	Scam Not_Scam	Sintético	https://huggingface.co/datasets/BothBosu/multi-agent-scam-conversation
Single Agent Scam Conversation (SASC)	Diálogo em texto	1600	Scam Not_Scam	Sintético	https://huggingface.co/datasets/BothBosu/single-agent-scam-conversations
Scammer Conversation (SSC)	Diálogo em texto	1000	Scam Not_Scam	Sintético	https://huggingface.co/datasets/BothBosu/Scammer-Conversation
Scam Dialogue (SSD)	Diálogo em texto	1600	Scam Not_Scam	Sintético	https://huggingface.co/datasets/BothBosu/scam-dialogue
Merged	Diálogo em texto	4431	Scam Not_Scam	Síntese dos 4 datasets sintéticos	-
TeleAntiFraud	Transcrições de chamadas	13 543	Fraud Not_-Fraud	Real	https://www.modelscope.cn/datasets/JimmyMa99/TeleAntiFraud

3.3 Análise Exploratória dos Dados (EDA)

Antes da aplicação das etapas de pré-processamento e representação textual, foi realizada uma análise exploratória dos dados. A EDA tem como objetivo o estudo da estrutura e das principais características dos datasets utilizados, serve como uma familiarização com cada um dos datasets. O número de exemplos disponíveis, a distribuição das classes, a existência de valores em falta nos casos dos datasets da fase exploratória, exemplos duplicados, variações no comprimento dos textos e inconsistências nos formatos das transcrições ou mensagens. Estes são fatores importantes, visto que são pequenos pormenores, que podem levar a diferenças nas performances dos modelos.

Nos datasets compostos por transcrições ou diálogos, a análise exploratória permitiu observar a existência de diferentes formas de identificar os intervenientes da conversa, justificando a posterior normalização desses identificadores. Nos datasets de texto curto, como os utilizados na fase exploratória, foram analisados elementos característicos de redes sociais, como URLs, menções, hashtags e pontuação.

A distribuição das classes foi um aspeto que também foi analisado, uma vez que problemas de deteção de fraude tendem frequentemente a apresentar desequilíbrio entre exemplos legítimos e fraudulentos. Esta informação é relevante para a escolha das métricas de avaliação, já que a utilização isolada de algumas métricas pode ser insuficiente em cenários onde uma classe é significativamente mais frequente do que a outra.

Outro aspeto considerado foi o comprimento dos textos após tokenização. A tokenização, como demonstrado na figura 3.2, corresponde ao processo de divisão de uma sequência de texto em unidades menores, designadas por *tokens*. Dependendo da abordagem utilizada, estes *tokens* podem corresponder a palavras, marcadores especiais ou outros elementos relevantes presentes no texto. Esta análise permitiu observar a variação no número de *tokens*, aspeto que serviu de base para a definição do comprimento máximo das sequências. Em vez de utilizar o comprimento do texto mais longo de todos, foi considerado o 95.º percentil dos comprimentos observados no conjunto de treino.

Assim, a análise exploratória dos dados teve um papel importante na definição das etapas seguintes do pipeline, nomeadamente no pré-processamento, na representação textual e na escolha das métricas utilizadas para a avaliação.

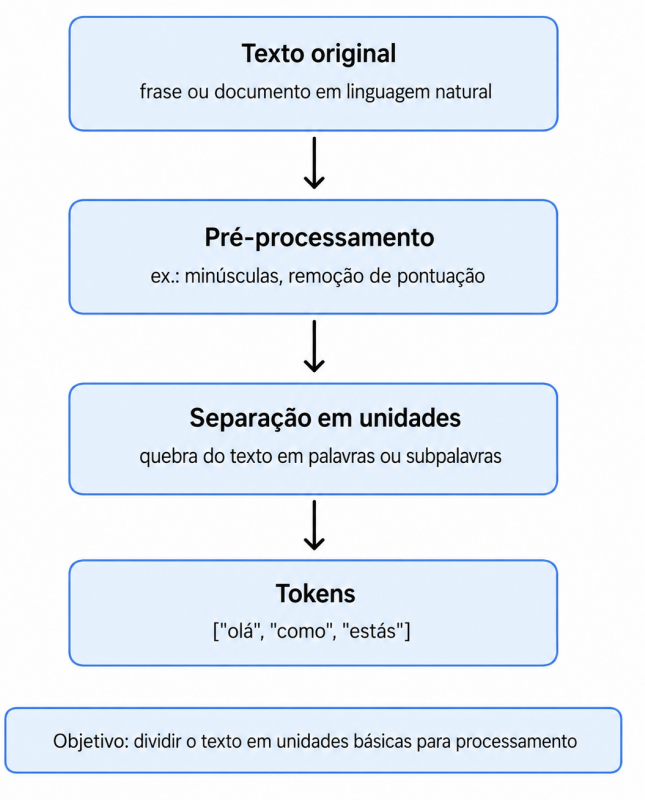


Figura 3.2: O processo de Tokenização

3.4 Pré-Processamento

O pré-processamento dos dados teve como principal objetivo reduzir ruído textual e uniformizar a estrutura dos exemplos antes da sua utilização pelos modelos de *Deep Learning*. Esta etapa é particularmente importante em tarefas de classificação de texto, uma vez que pequenas diferenças de formatação, identificadores inconsistentes, caracteres especiais ou espaços em excesso podem originar representações diferentes para conteúdos semanticamente semelhantes.

As operações de pré-processamento aplicadas variaram de acordo com a natureza de cada dataset. Apesar de existir um conjunto de procedimentos comuns, como a conversão do texto para minúsculas e a remoção de espaços extra, alguns datasets exigiram tratamento específico. Esta abordagem permitiu adaptar a limpeza textual às características dos dados, evitando aplicar transformações desnecessárias ou que levassem a potenciais perdas de informação.

Nos datasets compostos por transcrições ou diálogos, uma das principais etapas consistiu numa normalização dos identificadores dos intervenientes. Em cada um destes datasets, existem identificadores de turnos, isto é, expressões que identificam quem é a pessoa a quem diz respeito o texto que se segue. Estas expressões aparecem nas transcrições e diálogos em diferentes formatos, como: `"suspect:"`;`"innocent:"`;`"victim:"`; `"person a:"`;`"person b:"`;`"caller:"`;`"receiver:"`;`"[left]"`;`"[right]"`;

Esta variedade de expressões é desnecessária, visto que todas possuem o mesmo significado, a identificação do interveniente. Assim sendo, foram convertidos para tokens normalizados.`[CALLER]` e `[RECEIVER]`, referindo-se à pessoa que faz a chamada, e à pessoa que a recebe, respetivamente. Esta transformação teve como objetivo reduzir a variabilidade introduzida por diferentes convenções de anotação.

A preservação desta informação é relevante, uma vez que o conteúdo linguístico pode depender do papel desempenhado por cada interlocutor. Por exemplo, expressões de pressão, pedidos de informação sensível ou tentativas de manipulação podem surgir sobretudo do lado do suspeito, enquanto respostas de dúvida, hesitação ou fornecimento de dados podem surgir do lado do recetor. Assim, a normalização dos interlocutores permitiu manter alguma estrutura conversacional sem depender dos rótulos originais de cada dataset.

No caso dos datasets de texto curto utilizados na fase exploratória, como o dataset de *Disaster Tweets*, foram aplicadas operações adicionais adequadas ao formato dos dados. Estas incluíram a remoção de URLs, remoção de menções a utilizadores, remoção do símbolo # em hashtags, preservando a palavra associada, remoção de pontuação e normalização de espaços. Estas operações permitiram reduzir ruído característico de textos provenientes de redes sociais, mantendo a informação textual mais relevante para a tarefa de classificação. Um *link*, por exemplo, é algo que estes modelos não conseguem analisar, se ficasse presente no texto, seria apenas uma sequência de caracteres sem sentido. Sendo substituído por um *token: "link"*, o modelo já consegue atribuir-lhe um peso e um significado.

De forma geral, o pré-processamento aplicado procurou manter um equilíbrio entre a remoção de ruído que pudesse prejudicar a performance, e a preservação de informação semântica relevante. Por esse motivo, não foi adotada uma limpeza excessivamente agressiva do texto. Em particular, a remoção sistemática de *stop words* ou a aplicação de técnicas como *stemming* ou *lemmatização* não foram consideradas como parte central do pipeline, uma vez que os modelos de Deep Learning utilizados beneficiam da preservação da sequência textual e do contexto entre palavras.

Após esta etapa, os textos limpos foram encaminhados para a fase de representação textual, descrita na secção seguinte, onde foram convertidos para um formato numérico adequado ao treino dos modelos.

3.5 Representação Textual

Após o pré-processamento, os textos foram convertidos para uma representação numérica adequada à utilização pelos modelos de *Deep Learning*. Esta etapa é necessária porque modelos como CNN, LSTM ou GRU não processam diretamente texto em formato livre, exigindo que as palavras ou *tokens* sejam representados através de valores numéricos.

O primeiro passo desta transformação consistiu na tokenização dos textos. Depois deste processo, foi construído um vocabulário com base nos *tokens* presentes no conjunto de treino. Como a figura 3.3 demonstra, a cada *token* foi associado um identificador numérico, permitindo representar cada texto como uma sequência de índices. Esta transformação torna possível alimentar os modelos neuronais com sequências numéricas, mantendo a estrutura sequencial do texto original.

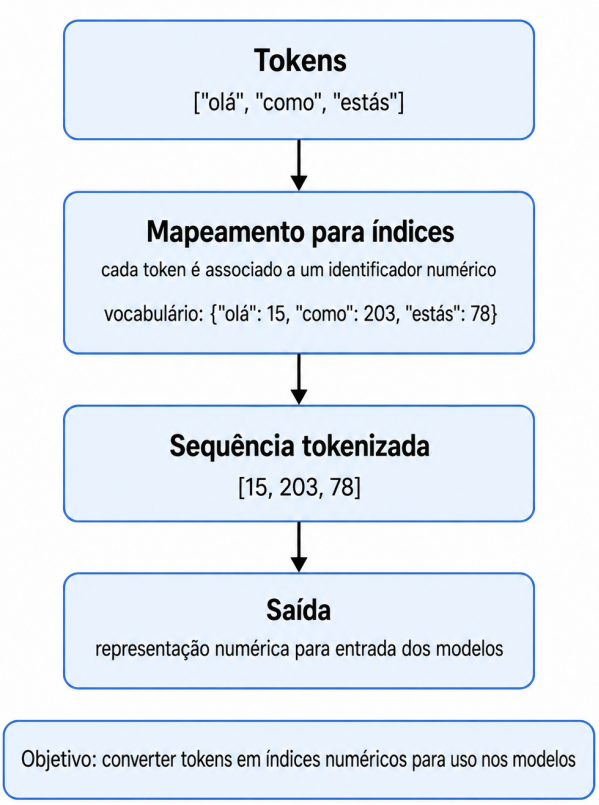


Figura 3.3: A criação do Vocabulário

No desenvolvimento experimental, o tokenizador foi configurado para considerar um máximo de 10000 *tokens* na criação do vocabulário. Esta limitação teve como objetivo controlar a dimensão da entrada dos modelos e reduzir o impacto de palavras muito pouco frequentes. Assim, durante a conversão dos textos para sequências numéricas, foram considerados principalmente os *tokens* mais frequentes do conjunto de treino.

Para lidar com palavras ou *tokens* não observados durante a fase de treino, foi utili-

zado um *token* especial para elementos desconhecidos, representado por <OOV>. Esta abordagem permite que textos dos conjuntos de validação ou teste contenham palavras fora do vocabulário sem impossibilitar o seu processamento pelo modelo, sendo estas associadas ao marcador de palavras desconhecidas.

O vocabulário por sua vez, foi construído apenas com base nos textos do conjunto de treino, de forma a evitar fuga de informação dos conjuntos de validação ou teste. Após esta etapa, o mesmo tokenizador foi utilizado para converter os textos dos restantes subconjuntos em sequências de índices numéricos.

Uma vez que os textos apresentam comprimentos variáveis, foi também necessária a aplicação de *padding*. Esta técnica consiste em acrescentar valores neutros às sequências mais curtas, de forma a garantir que todos os exemplos possuem o mesmo comprimento. Esta uniformização é necessária para permitir o treino em *batches* e para garantir compatibilidade com as arquiteturas neuronais utilizadas.

Nos casos em que uma sequência excedia o comprimento máximo definido, foi aplicado truncamento. O comprimento máximo das sequências foi definido de forma dinâmica, com base no 95.º percentil do número de *tokens* presentes nos textos do conjunto de treino. Esta escolha permitiu cobrir a maioria dos exemplos sem obrigar todos os textos a assumir o comprimento dos casos mais longos, reduzindo assim o custo computacional e a quantidade de *padding* introduzida. Tanto o *padding* como o truncamento foram aplicados no final das sequências.

Assim, o processo de representação textual que antecede os modelos pode ser resumido nas seguintes etapas: aplicação do pré-processamento, tokenização dos textos, criação do vocabulário, conversão dos *tokens* em índices numéricos e, por fim, aplicação de *padding* ou truncamento consoante necessário.

Nos modelos utilizados, estas sequências numéricas foram posteriormente transformadas em representações vetoriais através de camadas de *embedding*. Estas camadas permitem mapear cada *token* para um vetor denso, isto é, uma representação numérica compacta composta por valores contínuos, na qual tokens com funções ou significados semelhantes podem adquirir representações próximas no espaço vetorial. Desta forma, o modelo consegue aprender relações semânticas e padrões linguísticos relevantes para a tarefa de classificação.

3.6 Estratégia Experimental

A estratégia experimental foi definida com o objetivo de avaliar diferentes arquiteturas de *Deep Learning* aplicadas à tarefa de deteção de fraude em transcrições associadas a chamadas de voz. O problema foi formulado como uma tarefa de classificação supervisionada binária, na qual cada exemplo textual tem associado a si uma etiqueta que

indica se o conteúdo da chamada representa ou não uma comunicação fraudulenta.

O processo experimental seguiu um fluxo comum para os diferentes datasets utilizados. Numa primeira etapa, os dados foram carregados e analisados. No caso dos datasets com etiquetas textuais, estas foram convertidas para valores numéricos, de forma a poderem ser utilizadas pelas bibliotecas de treino e avaliação. Assim, a classe associada a fraude foi representada pelo valor 1, enquanto a classe não fraudulenta foi representada pelo valor 0.

No caso do dataset real, existiam exemplos sem etiqueta. Estes foram excluídos do processo de treino e avaliação supervisionada. Estes exemplos foram preservados separadamente, uma vez que podem ser utilizados posteriormente para análise qualitativa ou para aplicação dos modelos treinados, mas não foram considerados no cálculo das métricas de desempenho.

Para cada dataset, os textos foram inicialmente submetidos às etapas de pré-processamento e representação textual descritas nas secções anteriores. De seguida, os dados foram divididos em subconjuntos de treino, validação e teste. O conjunto de teste correspondeu a 20% dos exemplos disponíveis, sendo reservado exclusivamente para a avaliação final dos modelos. O restante conjunto foi novamente dividido, sendo 15% utilizado como conjunto de validação. Desta forma, a divisão final correspondeu aproximadamente a 68% dos dados para treino, 12% para validação e 20% para teste.

As divisões foram realizadas de forma estratificada, ou seja, preservando a proporção original das classes em cada subconjunto. Esta opção é particularmente relevante em problemas de deteção de fraude, nos quais pode existir desequilíbrio entre exemplos fraudulentos e não fraudulentos. A utilização de uma divisão estratificada reduz o risco de obter subconjuntos pouco representativos do universo de dados, especialmente quando a classe fraudulenta é menos frequente.

A avaliação experimental foi organizada em duas configurações principais. Na primeira, cada modelo foi treinado e testado no mesmo dataset, recorrendo à divisão em treino, validação e teste descritas anteriormente. Esta configuração permitiu avaliar o desempenho dos modelos em cada conjunto de dados de forma individual.

Numa segunda configuração, foi analisada a capacidade de generalização entre datasets. Para isso, os modelos foram treinados num determinado dataset e posteriormente avaliados nos restantes datasets. Esta abordagem permitiu observar até que ponto os padrões aprendidos num conjunto de dados se mantinham úteis quando aplicados a dados com características diferentes. Esta análise é particularmente relevante no contexto da deteção de fraude, uma vez que diferentes fontes de dados podem apresentar variações no estilo das transcrições, nos formatos dos diálogos e nos padrões linguísticos associados a comportamentos fraudulentos.

De forma a garantir consistência entre experiências, foi utilizado o mesmo procedi-

mento de tokenização, construção de vocabulário, aplicação de *padding* e truncamento para os diferentes modelos avaliados em cada dataset. O vocabulário foi limitado a 10000 *tokens*, foi utilizado um marcador para palavras fora do vocabulário e o comprimento máximo das sequências foi definido com base no 95.º percentil dos comprimentos observados no conjunto de treino.

A comparação experimental centrou-se em arquiteturas neuronais adequadas ao processamento de texto e sequências. Foram considerados modelos base, redes neuronais convolucionais e modelos recorrentes, incluindo variantes com unidades *LSTM* e *GRU*. Foram também avaliadas versões bidirecionais, como *Bi-LSTM* e *Bi-GRU*, com o objetivo de analisar se a consideração de contexto em ambas as direções, inicio ao fim e vice versa, da sequência beneficiava a tarefa de classificação.

Para assegurar uma comparação justa, os modelos foram treinados sobre as mesmas divisões de dados e avaliados sobre o mesmo conjunto de teste. O processo de treino foi realizado com um número fixo de épocas (este obteve-se através de um processo de otimização) e com o mesmo tamanho de *batch*, permitindo comparar o impacto das diferentes arquiteturas sob condições experimentais semelhantes. Durante o treino, o conjunto de validação foi utilizado para acompanhar a evolução do desempenho, identificar possíveis sinais de *overfitting*, e em determinados casos, como condição de paragem precoce, caso se verificasse que a melhoria na qualidade do modelo não era substancial.

Após o treino, cada modelo produziu uma probabilidade associada à classe positiva. A classificação final foi obtida através de um limiar de decisão de 0.5, classificando como fraude os exemplos cuja probabilidade prevista fosse superior a esse valor. Os resultados foram posteriormente agregados por modelo e por dataset, permitindo uma comparação direta através das métricas de avaliação apresentadas na secção seguinte.

3.7 Métricas de Avaliação

A avaliação dos modelos foi realizada com recurso a métricas adequadas a problemas de classificação binária. Tendo em conta o contexto da deteção de fraude, foi dada atenção não apenas ao desempenho global dos modelos, mas também à sua capacidade de identificar corretamente os exemplos fraudulentos.

A primeira métrica considerada foi a *accuracy*, que representa a proporção de classificações corretas face ao número total de exemplos avaliados. Esta métrica permite obter uma visão geral do desempenho do modelo, mas pode ser insuficiente quando existe desequilíbrio entre classes.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{3.1}$$

Em problemas de deteção de fraude, um modelo pode obter uma *accuracy* elevada simplesmente por favorecer a classe maioritária, falhando na identificação dos casos fraudulentos. Por esse motivo, foram também utilizadas as métricas *precision*, *recall* e *F1-score*.

A *precision* mede a proporção de exemplos classificados como fraude que correspondem efetivamente a casos fraudulentos. Esta métrica é relevante quando se pretende reduzir o número de falsos positivos, ou seja, situações em que uma comunicação legítima é incorretamente assinalada como fraudulenta.

$$Precision = \frac{TP}{TP + FP} \tag{3.2}$$

O *recall* mede a proporção de casos fraudulentos corretamente identificados pelo modelo. Esta métrica assume particular importância em cenários de deteção de fraude, uma vez que falsos negativos correspondem a situações em que uma comunicação fraudulenta não é detetada. Assim, um valor elevado de *recall* indica maior capacidade para identificar exemplos pertencentes à classe positiva.

$$Recall = \frac{TP}{TP + FN} \tag{3.3}$$

O *F1-score* combina *precision* e *recall* através da sua média harmónica, permitindo obter uma métrica equilibrada entre a fiabilidade das deteções realizadas e a capacidade de identificar casos fraudulentos. Esta métrica foi particularmente relevante para comparar modelos em situações em que existia compromisso entre falsos positivos e falsos negativos.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{3.4}$$

Para além destas métricas, foi utilizada em alguns casos a matriz de confusão, com o objetivo de visualizar de forma mais detalhada os tipos de erro cometidos pelos modelos. Esta matriz permite observar o número de TP (verdadeiros positivos), FP (falsos positivos), TN (verdadeiros negativos) e FN (falsos negativos), facilitando a visualização e interpretação do comportamento do modelo para cada classe.

De forma geral, a comparação entre modelos teve em consideração o conjunto destas métricas. Esta abordagem permitiu analisar de forma mais completa o desempenho dos modelos, especialmente no que diz respeito à identificação da classe fraudulenta.

3.8 Ferramentas Utilizadas

O desenvolvimento foi realizado com recurso à linguagem de programação Python, devido à sua ampla utilização em projetos de análise de dados, Machine Learning e Deep Learning, bem como ao vasto ecossistema de bibliotecas disponíveis para estas áreas.

A tabela 3.2 apresenta um resumo das principais ferramentas e bibliotecas utilizadas, bem como a respetiva finalidade no contexto do projeto.

Tabela 3.2: Ferramentas e bibliotecas utilizadas no desenvolvimento do projeto.

Ferramenta/Biblioteca	**Categoria**	**Finalidade no projeto**
PyCharm	IDE	Ambiente de desenvolvimento utilizado para escrita, organização e execução do código.
Python [27]	Linguagem de programação	Linguagem utilizada na implementação dos *scripts* de pré-processamento, treino e avaliação dos modelos.
NumPy [28] [29]	Computação numérica	Operações numéricas, manipulação de arrays e cálculo de estatísticas, como percentis para definição do comprimento máximo das sequências.
Pandas [30] [31]	Manipulação de dados	Carregamento, estruturação, limpeza e transformação dos datasets em formato tabular.
Scikit-learn [32] [33]	*Machine Learning* e avaliação	Divisão dos dados em treino, validação e teste, bem como cálculo das métricas de avaliação.
TensorFlow [34]& Keras [35]	*Deep Learning*	Construção, treino e avaliação das arquiteturas neuronais utilizadas, incluindo camadas, modelos, tokenização, *padding* e *callbacks*.
Matplotlib [36] [37]	Visualização de dados	Criação de gráficos para análise e comparação dos resultados obtidos.
Seaborn [38] [39]	Visualização de dados	Criação de visualizações complementares, nomeadamente gráficos comparativos e matrizes de confusão.
Outros (os, json, pickle, re, csv)	Bibliotecas standard de Python	Manipulação de ficheiros, leitura e escrita de dados, serialização de objetos, expressões regulares e carregamento manual de ficheiros CSV.

O ambiente de desenvolvimento utilizado foi o PyCharm, da JetBrains, que permitiu organizar os scripts, gerir o projeto e executar as experiências de forma estruturada.

Para além da linguagem e do ambiente de desenvolvimento, foram utilizadas várias bibliotecas Python ao longo do projeto. Estas bibliotecas desempenharam funções distintas, incluindo carregamento e manipulação de dados, pré-processamento textual, divisão dos dados, construção e treino dos modelos, cálculo de métricas e visualização dos resultados.

4 Trabalho Realizado/Implementação

Este capítulo apresenta o trabalho prático desenvolvido ao longo do projeto. Após a definição da metodologia, dos datasets, das etapas de pré-processamento e da estratégia experimental, descritas no capítulo anterior, procede-se agora à descrição concreta da abordagem implementada e dos modelos desenvolvidos.

Como já foi referido anteriormente, o trabalho prático foi organizado em duas fases principais. A primeira teve um caráter exploratório e permitiu testar procedimentos comuns de classificação, pré-processamento, tokenização e avaliação. A segunda fase correspondeu à aplicação das técnicas estudadas ao domínio principal do projeto, centrando-se na deteção de fraude em comunicações de voz e respetivas transcrições, com recurso a arquiteturas neuronais.

4.1 Fase Exploratória

O objetivo desta fase não foi obter conclusões diretamente relacionadas com fraude em chamadas de voz, mas sim validar o fluxo de trabalho experimental. Foram testadas operações como carregamento dos dados, análise da estrutura dos datasets, limpeza e normalização, divisão em conjuntos de treino e teste, treino de modelos e cálculo de métricas de avaliação.

Nos datasets textuais, como *Disaster Tweets* e análise de sentimentos, esta fase permitiu testar técnicas de processamento de texto, tokenização, representação vetorial e classificação. Já no dataset de classificação de vinhos, o foco incidiu sobretudo em conceitos gerais de classificação supervisionada, normalização de atributos numéricos e avaliação de desempenho.

Esta fase foi importante para reduzir incertezas técnicas antes da fase de especialização. Através dela foi possível estabelecer uma base comum de trabalho, identificar ferramentas adequadas e compreender melhor o impacto das decisões de pré-processamento e representação dos dados no desempenho dos modelos.

4.2 Implementação da Abordagem de Deep Learning

A fase de especialização centrou-se na implementação de modelos de *Deep Learning* aplicados à classificação de transcrições e diálogos potencialmente fraudulentos. O processo implementado seguiu o pipeline definido na metodologia, apresentada na

Figura 3.1, iniciando-se com o carregamento dos datasets, seguindo-se o processo de pré-processamento textual, a tokenização, a aplicação de *padding*, o treino dos modelos e, por fim, a avaliação dos resultados.

Cada dataset foi inicialmente carregado e convertido para uma estrutura tabular uniforme. A tabela 4.1 mostra um excerto de uma destas tabelas. Cada uma contendo pelo menos uma coluna para texto e uma coluna com a respetiva *label*. Nos casos em que os datasets apresentavam formatos irregulares, foi necessário efetuar um carregamento manual dos dados e selecionar apenas os campos relevantes para a tarefa de classificação.

Tabela 4.1: Excerto da tabela relativa ao Dataset *TeleAntiFraud*

Label	**Diálogo**
fraud	"[left] Hello. [right] Hello. [left] I am Lee from the Financial Investment Advisory Centre and we have noticed that you are looking [...]

As etiquetas foram convertidas para valores numéricos, representando a classe fraudulenta pelo valor 1 e a classe não fraudulenta pelo valor 0. Esta transformação foi necessária para permitir a utilização das bibliotecas de treino e avaliação. No caso do dataset real, os exemplos sem etiqueta foram separados do conjunto principal, uma vez que não podiam ser utilizados no treino supervisionado nem no cálculo das métricas de desempenho.

Após o pré-processamento textual, os textos foram convertidos para sequências numéricas através de um tokenizador. Foi utilizado um vocabulário máximo de 10000 *tokens*, sendo definido um marcador especial para palavras fora do vocabulário. O comprimento máximo das sequências foi determinado com base no 95.º percentil dos comprimentos observados, reduzindo o impacto de textos excecionalmente longos e evitando a introdução excessiva de *padding*.

Os dados foram depois divididos em conjuntos de treino, validação e teste. O conjunto de treino foi utilizado para ajustar os pesos dos modelos, o conjunto de validação para acompanhar o desempenho durante o treino e o conjunto de teste para avaliar a capacidade de generalização dos modelos em exemplos não vistos.

A implementação dos modelos foi realizada com recurso à API Keras [35] do TensorFlow. Todos os modelos foram definidos como arquiteturas sequenciais, compostas por uma camada de entrada, uma camada de *embedding*, camadas específicas da arquitetura testada e uma camada final de saída com ativação sigmoide. Esta última camada permitiu produzir uma probabilidade associada à classe positiva, correspondente à classe fraudulenta.

4.3 Modelos Desenvolvidos

Foram implementadas e avaliadas várias arquiteturas de *Deep Learning*, com o objetivo de comparar diferentes formas de extrair padrões relevantes a partir de texto. Os modelos desenvolvidos incluíram um modelo base, modelos recorrentes com unidades LSTM e GRU, versões bidirecionais dessas arquiteturas e uma rede neuronal convolucional.

Apesar das diferenças entre arquiteturas, todos os modelos seguiram uma estrutura geral semelhante. As sequências numéricas resultantes da tokenização foram inicialmente transformadas em vetores densos através de uma camada de *embedding*. Esta camada permitiu representar cada *token* num espaço vetorial contínuo, servindo de entrada para as camadas seguintes.

A camada final foi comum a todos os modelos, consistindo numa unidade densa com ativação sigmoide. Esta configuração é adequada a problemas de classificação binária, uma vez que produz um valor entre 0 e 1, interpretado como a probabilidade de o exemplo pertencer à classe fraudulenta. Todos os modelos foram compilados com a função de perda *binary crossentropy*, o otimizador Adam e a métrica *accuracy* durante o treino.

4.3.1 O Modelo Base

O modelo base foi implementado como uma arquitetura simples, servindo como ponto de comparação para os modelos mais complexos. A figura 4.1 demonstra a sua estrutura. Consistiu numa camada de entrada, uma camada de *embedding*, uma camada *GlobalAveragePooling1D*, uma camada densa intermédia, uma camada de *dropout* e uma camada final de saída.

A camada de *embedding* foi configurada com dimensão de saída igual a 128, permitindo transformar os índices dos *tokens* em vetores densos. De seguida, a camada *GlobalAveragePooling1D* agregou a informação ao longo da sequência, produzindo uma representação fixa para cada texto. Esta representação foi depois processada por uma camada densa com 64 neurónios e função de ativação ReLU.

Foi utilizada uma camada de *dropout* com taxa de 0.5, esta é uma técnica de regularização que desliga aleatoriamente uma % dos neurónios da rede, tentando assim reduzir o risco de *overfitting*. Por fim, a camada de saída utilizou uma função de ativação sigmoide para produzir a probabilidade associada à classe fraudulenta.

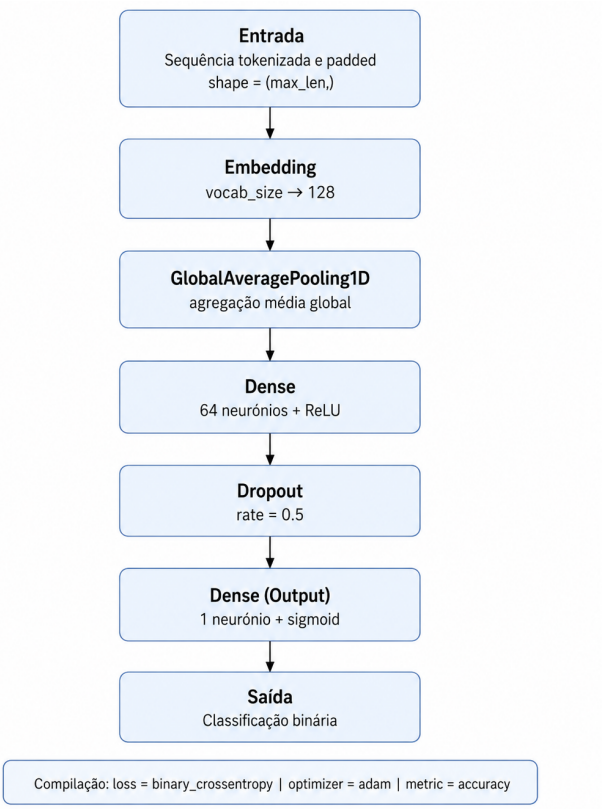


Figura 4.1: Arquitetura do Modelo Base

Este modelo apresenta menor complexidade computacional do que as arquiteturas recorrentes ou convolucionais. Por esse motivo, foi utilizado como referência inicial para avaliar se modelos mais complexos apresentavam ganhos relevantes de desempenho, ou se um modelo mais simples já seria capaz de obter resultados competitivos.

4.3.2 LSTM e GRU

Foram também implementados modelos recorrentes baseados em unidades LSTM e GRU. Estas arquiteturas são particularmente adequadas ao processamento de sequências, uma vez que permitem analisar a ordem dos *tokens* e capturar dependências ao longo do texto. A figura 4.2 é um esquema que demonstra ambas as arquiteturas.

Como mostra a figura o modelo LSTM foi composto por uma camada de entrada, uma camada de *embedding*, uma camada *SpatialDropout1D*, uma camada LSTM com 64 unidades, uma camada de *dropout* e uma camada final de saída. A camada *SpatialDropout1D*, com taxa de 0.2, foi utilizada para reduzir dependências excessivas em determinadas dimensões dos *embeddings*, contribuindo para uma maior capacidade de generalização.

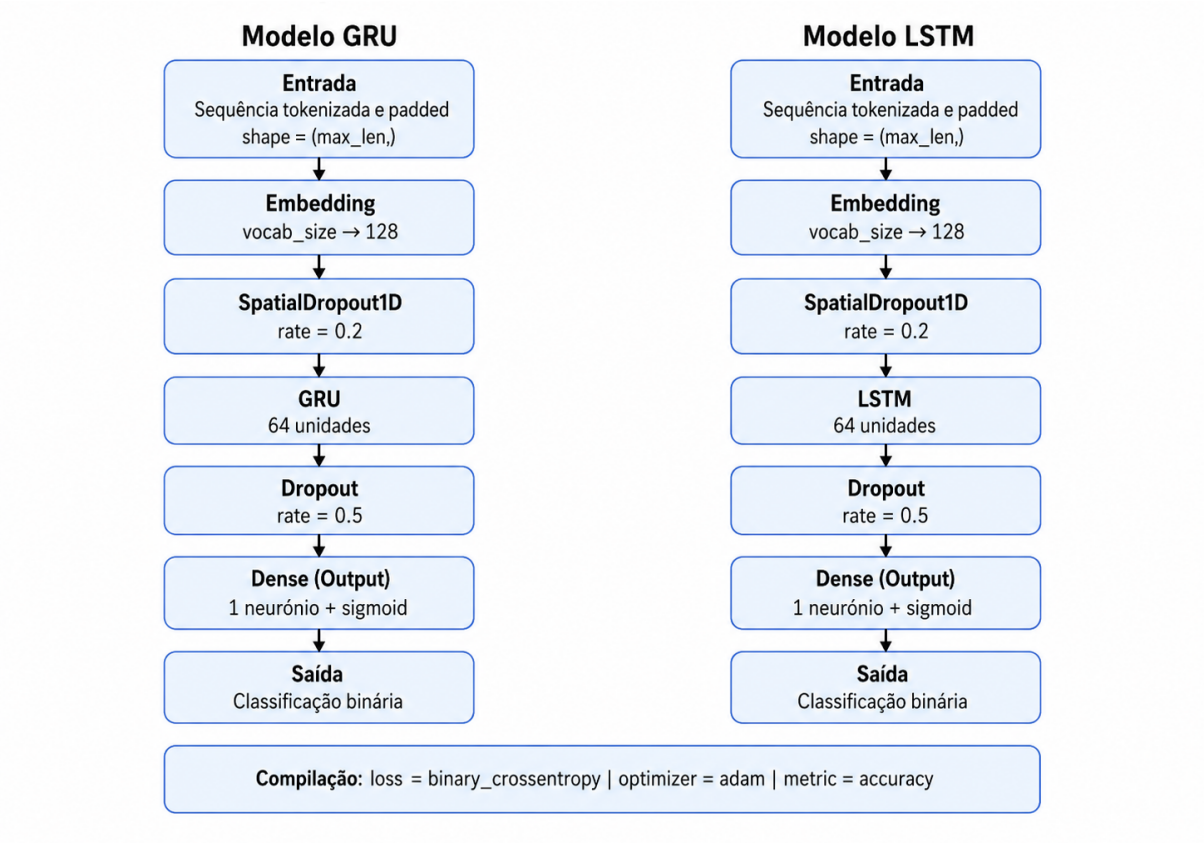


Figura 4.2: Arquitetura dos Modelos LSTM e GRU

O modelo GRU seguiu uma estrutura semelhante, substituindo a camada LSTM por uma camada GRU com 64 unidades. As unidades GRU constituem uma alternativa às LSTM, apresentando uma estrutura interna mais simples e, em muitos casos, menor custo computacional. A comparação entre LSTM e GRU permitiu avaliar se a maior complexidade das LSTM se traduzia em ganhos relevantes no contexto da deteção de fraude em transcrições.

Ambos os modelos foram concebidos para analisar padrões sequenciais presentes no texto, como expressões de urgência, pedidos de informação sensível, referências a pagamentos ou outros sinais linguísticos potencialmente associados a fraude.

4.3.3 Bi-LSTM e Bi-GRU

Para além das versões unidirecionais, foram implementadas variantes bidirecionais dos modelos recorrentes utilizados, nomeadamente Bi-LSTM e Bi-GRU. A figura 4.3 contém um esquema simples de ambas as arquiteturas.

Estas arquiteturas processam a sequência em duas direções: do início para o fim e do fim para o início. A bidirecionalidade introduzida nestes modelos tem uma grande vantagem. O facto de analisarem o texto em ambas as direções permite-lhes em qualquer altura ter a possibilidade de considerar contexto anterior e posterior a cada ponto

da sequência. Em tarefas de classificação textual, esta característica pode ser extremamente útil, uma vez que o significado de uma expressão pode depender não apenas das palavras que a antecedem, mas também das palavras que surgem posteriormente.

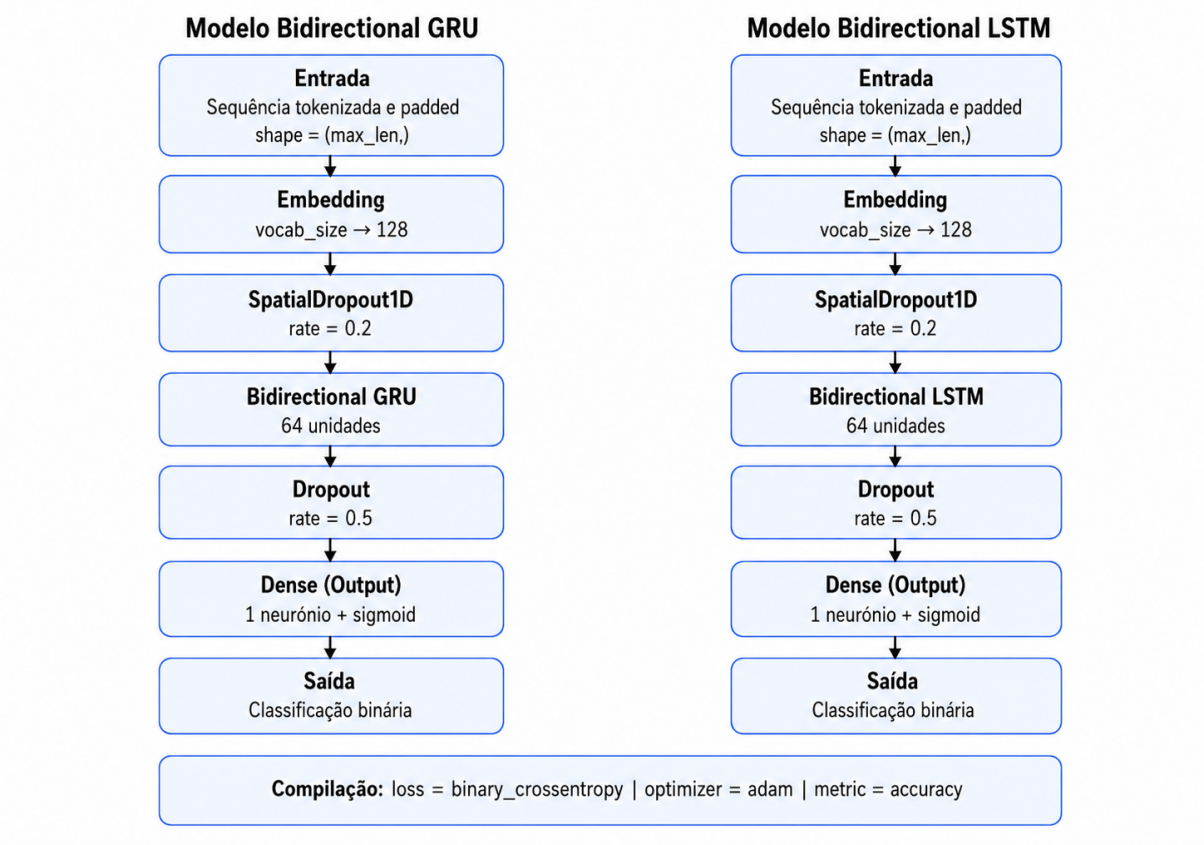


Figura 4.3: Arquitetura dos Modelos LSTM e GRU Bidirecionais

O modelo Bi-LSTM foi composto por uma camada de entrada, uma camada de *embedding*, uma camada *SpatialDropout1D*, uma camada LSTM bidirecional com 64 unidades, uma camada de *dropout* e uma camada final de saída. O modelo Bi-GRU seguiu a mesma estrutura, substituindo a camada LSTM pela respetiva versão GRU.

A inclusão destas arquiteturas permitiu avaliar se o processamento bidirecional beneficiava a tarefa de deteção de fraude, especialmente em diálogos ou transcrições onde a interpretação de determinadas expressões pode depender do contexto global da conversa.

4.3.4 Convolutional Neural Networks

Foi ainda implementado um modelo baseado em redes neuronais convolucionais, com o objetivo de avaliar a capacidade das CNN em identificar padrões locais no texto. Embora sejam frequentemente associadas ao processamento de imagem, as CNN também são utilizadas em tarefas de classificação textual, onde conseguem detetar combinações de palavras ou expressões relevantes.

A arquitetura implementada, apresentada na figura 4.4, foi composta por uma camada de entrada, uma camada de *embedding*, uma camada *SpatialDropout1D*, uma camada convolucional unidimensional, uma camada *GlobalMaxPooling1D*, uma camada densa intermédia, uma camada de *dropout* e uma camada final de saída.

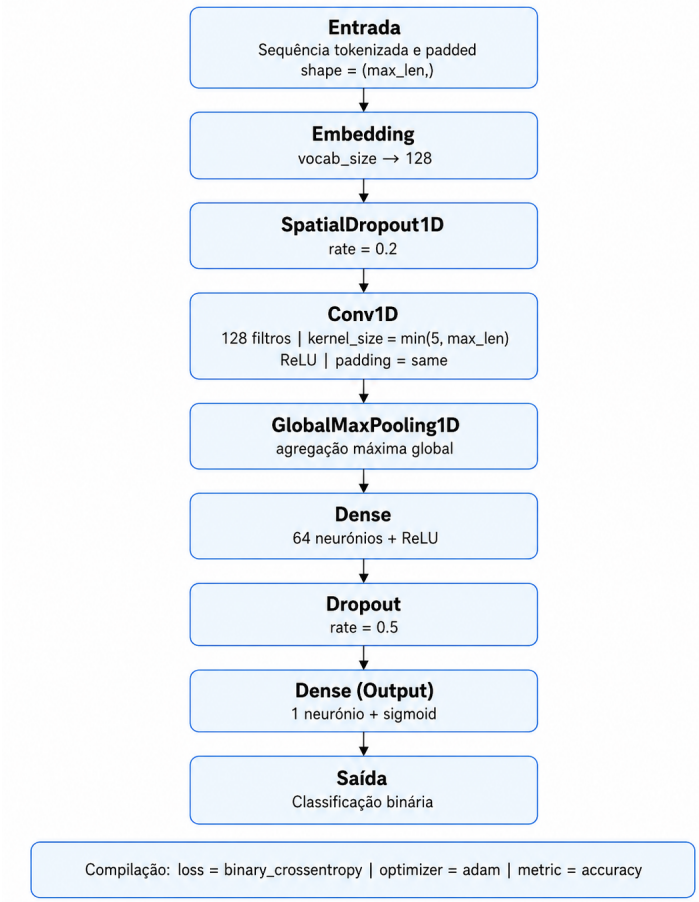


Figura 4.4: Arquitetura dos Modelos CNN para texto

A camada convolucional utilizou 128 filtros e função de ativação ReLU. O tamanho do *kernel* foi definido como o menor valor entre 5 e o comprimento máximo da sequência, garantindo compatibilidade com datasets onde o comprimento das sequências pudesse ser reduzido. Esta camada teve como objetivo identificar padrões locais de *tokens*, como expressões curtas ou combinações de palavras associadas a comportamentos fraudulentos.

Após a convolução, a camada *GlobalMaxPooling1D* selecionou as ativações mais relevantes ao longo da sequência, produzindo uma representação compacta do texto. Esta representação foi depois processada por uma camada densa com 64 neurónios e uma camada de *dropout* com taxa de 0.5, antes da classificação final.

A utilização do modelo CNN permitiu comparar uma abordagem focada em padrões locais com a abordagem dos modelos recorrentes, que procuram capturar dependências sequenciais ao longo do texto.

De forma a sintetizar as arquiteturas descritas nas subsecções anteriores, a Tabela 4.2 apresenta um resumo dos modelos implementados, incluindo a sua estrutura geral e o principal objetivo da sua utilização no contexto do projeto.

Tabela 4.2: Resumo das arquiteturas implementadas

Modelo	**Arquitetura geral**	**Objetivo**
Modelo Base	Embedding → GlobalAveragePooling1D → Dense → Dropout → Saída	Servir como referência simples de comparação
LSTM	Embedding → SpatialDropout1D → LSTM → Dropout → Saída	Capturar dependências sequenciais no texto
GRU	Embedding → SpatialDropout1D → GRU → Dropout → Saída	Avaliar uma alternativa recorrente mais simples que LSTM
Bi-LSTM	Embedding → SpatialDropout1D → Bidirectional LSTM → Dropout → Saída	Analisar contexto em ambas as direções da sequência
Bi-GRU	Embedding → SpatialDropout1D → Bidirectional GRU → Dropout → Saída	Avaliar processamento bidirecional com menor complexidade que Bi-LSTM
CNN	Embedding → SpatialDropout1D → Conv1D → GlobalMaxPooling1D → Dense → Dropout → Saída	Identificar padrões locais de palavras ou expressões

Esta comparação permitiu avaliar diferentes formas de extração de informação a partir de texto, desde abordagens mais simples baseadas em agregação global dos *embeddings*, até modelos capazes de capturar padrões sequenciais ou locais.

4.4 Configuração Experimental

A configuração experimental foi definida de forma a manter condições comparáveis entre os diferentes modelos implementados. Assim, sempre que possível, foram utilizados os mesmos procedimentos de representação textual, divisão dos dados e avaliação descritos no Capítulo 3, permitindo que as diferenças observadas nos resultados fossem atribuídas sobretudo às arquiteturas testadas.

Todos os modelos receberam como entrada sequências numéricas resultantes do processo de tokenização, aplicação de *padding* e truncamento. O vocabulário foi limitado a 10000 *tokens*, tendo sido utilizado um marcador especial para palavras fora do vocabulário, um *token* <OOV> (*out of vocabulary*). O comprimento máximo das sequências foi definido para cada dataset com base no 95.º percentil dos comprimentos observados no conjunto de treino, conforme descrito na Secção 3.5.

As sequências de entrada foram transformadas em representações vetoriais através de

camadas de *embedding*, com dimensão de saída igual a 128. Estas camadas foram treinadas juntamente com as restantes camadas de cada modelo, não tendo sido utilizados *embeddings* pré-treinados. Esta opção permitiu que as representações fossem aprendidas diretamente a partir dos datasets utilizados, adaptando-se aos padrões linguísticos presentes nas transcrições e diálogos analisados.

Para reduzir o risco de *overfitting*, foram utilizadas técnicas de regularização nos modelos implementados. Nos modelos recorrentes e convolucionais foi aplicada uma camada *SpatialDropout1D* após a camada de *embedding*, com taxa de 0.2. Para além disso, foi utilizada uma camada de *dropout* com taxa de 0.5 antes da camada final de saída.

A camada de saída foi comum a todos os modelos, sendo composta por uma unidade densa com função de ativação sigmoide. Esta configuração é adequada a problemas de classificação binária, uma vez que permite produzir uma probabilidade associada à classe positiva, correspondente à classe fraudulenta. A função de perda utilizada foi *binary crossentropy* e o otimizador utilizado foi o Adam.

Durante o treino, o conjunto de validação foi utilizado para acompanhar a evolução do desempenho dos modelos e identificar possíveis sinais de *overfitting*. Em algumas experiências foi aplicado *early stopping*, interrompendo o treino quando não se verificavam melhorias relevantes no desempenho de validação. A conversão das probabilidades produzidas pelos modelos em classes finais foi realizada com o limiar de decisão definido na metodologia, igual a 0.5.

A seleção dos hiperparâmetros combinou diferentes critérios. Alguns valores foram definidos com base em configurações comuns em tarefas de classificação textual e nos valores padrão disponibilizados pelas bibliotecas utilizadas. Outros foram ajustados empiricamente através de testes preliminares, procurando obter um compromisso entre desempenho, estabilidade do treino e custo computacional. A tabela 4.3 resume de forma simples os principais hiperparâmetros que foram considerados. Esta abordagem permitiu assim manter uma configuração relativamente simples e comparável entre modelos, sem realizar uma otimização exaustiva de hiperparâmetros.

Tabela 4.3: Principais hiperparâmetros utilizados nas experiências.

Hiperparâmetro	**Valor utilizado**	**Critério de escolha**
Tamanho máximo do vocabulário	10000 *tokens*	Valor fixo utilizado para limitar a dimensão da representação textual e reduzir o impacto de palavras raras
Dimensão dos *embeddings*	128	Valor definido empiricamente, procurando equilibrar capacidade de representação e custo computacional
Unidades LSTM/GRU	64	Valor definido empiricamente durante testes preliminares
Filtros da CNN	128	Valor definido empiricamente para permitir a deteção de padrões locais no texto
Tamanho do *kernel* da CNN	$\min(5, max_len)$	Definido para capturar padrões locais, garantindo compatibilidade com sequências curtas
Taxa de *SpatialDropout1D*	0.2	Valor usado como regularização após a camada de *embedding*
Taxa de *Dropout*	0.5	Valor usado para reduzir o risco de *overfitting* antes da camada de saída
Função de perda	*binary crossentropy*	Adequada a problemas de classificação binária
Otimizador	Adam	Valor padrão/comum em tarefas de *Deep Learning*
Ativação da saída	*sigmoide*	Adequada para produzir uma probabilidade associada à classe positiva
Limiar de decisão	0.5	Valor padrão para conversão da probabilidade em classe binária

5 Resultados e Discussão

Este capítulo apresenta e discute os resultados obtidos durante a fase experimental do projeto. Após a descrição da metodologia adotada e da implementação dos modelos de *Deep Learning*, procede-se agora à análise do desempenho das arquiteturas desenvolvidas nos diferentes datasets utilizados.

A avaliação centrou-se sobretudo na fase de especialização [1], uma vez que esta corresponde ao domínio principal do trabalho: a deteção de fraude em transcrições e diálogos associados a chamadas de voz. A fase exploratória, embora importante para a familiarização com técnicas de classificação, pré-processamento, tokenização e avaliação de modelos, não teve como objetivo produzir conclusões diretamente relacionadas com fraude em telecomunicações. Por esse motivo, os seus resultados são considerados apenas como parte do processo de preparação e validação inicial do pipeline experimental.

Os resultados apresentados neste capítulo são analisados com base nas métricas descritas anteriormente, nomeadamente *accuracy*, *precision*, *recall* e *F1-score*. Sempre que relevante, são também consideradas matrizes de confusão, de forma a compreender melhor os tipos de erro cometidos pelos modelos, em particular falsos positivos e falsos negativos.

A análise encontra-se organizada em diferentes níveis. Em primeiro lugar, são apresentados os resultados obtidos nos datasets da fase de especialização. De seguida, é realizada uma comparação entre as diferentes arquiteturas de *Deep Learning*, procurando identificar quais os modelos com melhor desempenho e quais os compromissos observados entre as métricas. Posteriormente, é analisada a capacidade de generalização dos modelos entre diferentes datasets, com especial atenção às diferenças entre dados sintéticos e dados reais. Por fim, são discutidas as principais limitações observadas ao longo do processo experimental.

5.1 Resultados da Fase de Especialização

Os resultados da fase de especialização são apresentados individualmente por dataset, de forma a facilitar a análise do desempenho dos modelos em cada conjunto de dados.

[1] No contexto deste projeto, a fase de especialização corresponde à fase do estudo dos datasets de fraude em telecomunicações com rescurso a modelos DL

Esta organização permite observar diferenças entre datasets sintéticos e o dataset real, bem como comparar o comportamento das arquiteturas em cenários com características distintas.

Para cada dataset foram avaliados os modelos descritos no capítulo anterior: Modelo Base, LSTM, GRU, Bi-LSTM, Bi-GRU e CNN. As métricas apresentadas correspondem à *accuracy*, *precision*, *recall* e *F1-score*. A interpretação dos resultados deve ter em conta que vários dos datasets utilizados nesta fase são sintéticos, apresentando uma estrutura mais regular e padrões linguísticos mais controlados do que aqueles que seriam esperados em transcrições reais de chamadas.

A tabela 5.1, mostra os resultados obtidos no dataset MASC, este é um dataset sintético com 1600 instâncias.

Tabela 5.1: Resultados no dataset *Multi Agent Scam Conversation* (MASC).

Modelo	**Accuracy**	**Precision**	**Recall**	**F1-score**
Modelo Base	0.9938	0.9877	1.0000	0.9938
LSTM	0.5188	0.7500	0.0563	0.1047
GRU	0.5125	0.6667	0.0500	0.0930
Bi-LSTM	1.0000	1.0000	1.0000	1.0000
Bi-GRU	1.0000	1.0000	1.0000	1.0000
CNN	1.0000	1.0000	1.0000	1.0000

A tabela 5.2 mostra os resultados obtidos para o dataset SASC, outro dataset sintético com 1600 isntâncias.

Tabela 5.2: Resultados no dataset *Single Agent Scam Conversation* (SASC).

Modelo	**Accuracy**	**Precision**	**Recall**	**F1-score**
Modelo Base	1.0000	1.0000	1.0000	1.0000
LSTM	0.9906	0.9816	1.0000	0.9907
GRU	0.9938	0.9938	0.9938	0.9938
Bi-LSTM	1.0000	1.0000	1.0000	1.0000
Bi-GRU	1.0000	1.0000	1.0000	1.0000
CNN	1.0000	1.0000	1.0000	1.0000

A tabela 5.3 mosta os resultados do dataset SSC, o mais pequeno dos datasets sintéticos, apenas 1000 instâncias.

Tabela 5.3: Resultados no dataset *Scammer Conversation* (SSC).

Modelo	**Accuracy**	**Precision**	**Recall**	**F1-score**
Modelo Base	1.0000	1.0000	1.0000	1.0000
LSTM	1.0000	1.0000	1.0000	1.0000
GRU	1.0000	1.0000	1.0000	1.0000
Bi-LSTM	1.0000	1.0000	1.0000	1.0000
Bi-GRU	1.0000	1.0000	1.0000	1.0000
CNN	1.0000	1.0000	1.0000	1.0000

Por fim, a tabela 5.4 mostra os resultados obtidos para o último dataset sintético, SSD.

Tabela 5.4: Resultados no dataset *Scam Dialogue* (SSD).

Modelo	**Accuracy**	**Precision**	**Recall**	**F1-score**
Modelo Base	1.0000	1.0000	1.0000	1.0000
LSTM	0.9812	0.9639	1.0000	0.9816
GRU	1.0000	1.0000	1.0000	1.0000
Bi-LSTM	1.0000	1.0000	1.0000	1.0000
Bi-GRU	1.0000	1.0000	1.0000	1.0000
CNN	1.0000	1.0000	1.0000	1.0000

De forma geral, os resultados obtidos nos datasets sintéticos (tabelas 5.1, 5.2, 5.3 e 5.4) foram muito elevados, sendo frequente a obtenção de valores iguais ou próximos de 1.0000 nas diferentes métricas. Este comportamento indica que os modelos conseguiram distinguir eficazmente as duas classes nestes conjuntos de dados. No entanto, estes resultados devem ser interpretados tendo em conta a natureza sintética dos datasets, uma vez que estes tendem a apresentar diálogos mais estruturados, padrões linguísticos mais repetitivos e uma menor variedade de vocabulário do que comunicações reais.

Nos datasets SASC, SSC e SSD, a maioria dos modelos obteve desempenho perfeito ou quase perfeito, o que sugere que a tarefa de classificação nestes conjuntos de dados é relativamente simples para as arquiteturas avaliadas. Este resultado é particularmente visível no dataset SSC, onde todos os modelos obtiveram valores de 1.0000 em todas as métricas. Nestes casos, a elevada separabilidade dos dados faz com que a complexidade adicional de alguns modelos não se traduza numa diferença significativa de desempenho face ao Modelo Base.

O dataset MASC apresentou um comportamento ligeiramente diferente, uma vez que os modelos LSTM e GRU obtiveram resultados bastante inferiores aos restantes. Em particular, os baixos valores de *recall* indicam dificuldades destes modelos em identifi-

car corretamente exemplos da classe positiva. Uma possível explicação para este comportamento está relacionada com o maior comprimento das sequências neste dataset, que pode dificultar a aprendizagem de modelos recorrentes unidirecionais. Ainda assim, os modelos Bi-LSTM, Bi-GRU e CNN obtiveram resultados perfeitos, sugerindo que arquiteturas bidirecionais ou convolucionais foram mais adequadas para lidar com os padrões presentes neste conjunto de dados.

A figura 5.1 resume visualmente o conjunto das métricas observadas para estes conjuntos de dados.

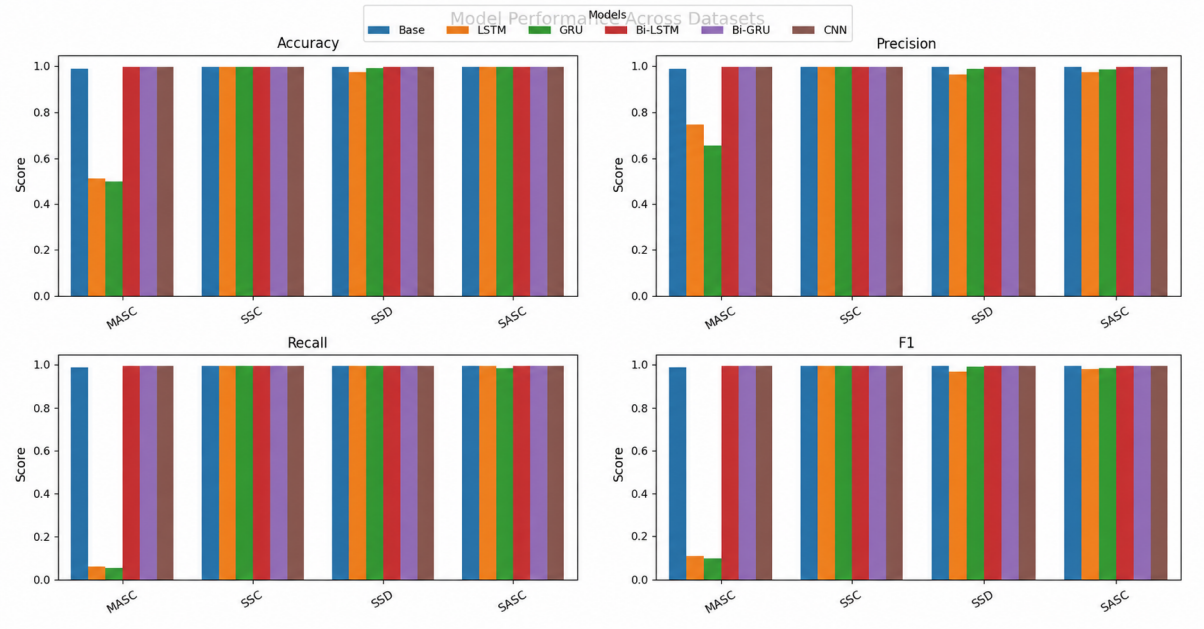


Figura 5.1: Resumo visual das métricas nos Datasets Sintéticos

Devido à simplicidade dos dados dos datasets sintétiicos, estes resultados não devem ser considerados suficientes para avaliar a aplicabilidade dos modelos em cenários reais. Por esse motivo, a avaliação no dataset TeleAntiFraud assume particular importância, uma vez que permite analisar o desempenho dos modelos num conjunto de transcrições mais próximo do domínio real de aplicação.

A Tabela 5.5 apresenta os resultados obtidos no dataset TeleAntiFraud. Ao contrário dos datasets anteriores, este conjunto de dados contém transcrições de chamadas reais ou mais próximas de um cenário real, sendo por isso esperado um maior grau de variabilidade textual e uma tarefa de classificação potencialmente mais desafiante.

Tabela 5.5: Resultados no dataset TeleAntiFraud.

Modelo	**Accuracy**	**Precision**	**Recall**	**F1-score**
Modelo Base	0.9978	1.0000	0.9959	0.9979
LSTM	0.9982	0.9973	0.9993	0.9983
GRU	0.9985	0.9980	0.9993	0.9986
Bi-LSTM	0.9989	0.9993	0.9986	0.9990
Bi-GRU	0.9779	0.9606	1.0000	0.9799
CNN	0.9985	0.9993	0.9979	0.9986

Os resultados obtidos no dataset TeleAntiFraud foram também bastante elevados em todos os modelos avaliados. Este comportamento indica que as arquiteturas implementadas conseguiram identificar padrões relevantes nas transcrições de chamadas, mesmo num conjunto de dados mais próximo do domínio real de aplicação. Ainda assim, ao contrário dos datasets sintéticos, estes resultados assumem maior relevância para a avaliação do projeto, uma vez que este dataset apresenta uma estrutura mais representativa do problema de deteção de fraude em comunicações de voz.

Entre os modelos avaliados, a Bi-LSTM obteve o melhor desempenho global, com uma *accuracy* de 0.9989 e um *F1-score* de 0.9990. Este resultado sugere que a análise bidirecional da sequência foi vantajosa neste dataset, permitindo ao modelo considerar informação contextual em ambas as direções. A CNN e a GRU apresentaram também resultados muito próximos, ambas com *accuracy* de 0.9985 e *F1-score* de 0.9986, o que demonstra que tanto a deteção de padrões locais como a modelação sequencial foram eficazes neste conjunto de dados.

O Modelo Base apresentou igualmente um desempenho muito competitivo, com *accuracy* de 0.9978 e *F1-score* de 0.9979. Apesar da sua menor complexidade, este modelo conseguiu obter uma *precision* de 1.0000, o que significa que, no conjunto de teste utilizado, não classificou incorretamente exemplos negativos como fraudulentos. Este resultado mostra que, neste dataset, existem padrões textuais suficientemente discriminativos para serem capturados mesmo por uma arquitetura simples baseada na agregação dos *embeddings*.

A Bi-GRU foi o modelo com menor desempenho relativo, apresentando uma *accuracy* de 0.9779 e um *F1-score* de 0.9799. Apesar disso, obteve um *recall* de 1.0000, indicando que identificou todos os exemplos fraudulentos do conjunto de teste. A redução do seu desempenho deve-se, portanto, sobretudo à menor *precision*, o que sugere um maior número de falsos positivos. Num contexto de deteção de fraude, este comportamento pode ser aceitável em cenários onde se pretende maximizar a deteção de casos suspeitos, mas pode também gerar mais sinalizações indevidas de chamadas legítimas.

A análise do equilíbrio entre *precision* e *recall* é particularmente importante neste domínio. Um valor elevado de *recall* reduz a probabilidade de chamadas fraudulentas

passarem despercebidas, enquanto uma *precision* elevada reduz o número de chamadas legítimas classificadas incorretamente como fraude. Neste sentido, modelos como a Bi-LSTM, a CNN e a GRU apresentam um equilíbrio particularmente favorável entre ambas as métricas, tornando-se opções adequadas para este tipo de tarefa.

De forma geral, os resultados no TeleAntiFraud confirmam que os modelos de *Deep Learning* avaliados foram capazes de obter um desempenho muito elevado na deteção de fraude em transcrições de chamadas. A proximidade entre os resultados de vários modelos sugere, contudo, que a escolha da arquitetura não deve depender apenas do valor máximo das métricas, mas também de fatores como complexidade, custo computacional, estabilidade e capacidade de generalização. Neste contexto, a CNN e o Modelo Base destacam-se como alternativas particularmente interessantes, por combinarem desempenho elevado com arquiteturas relativamente simples.

5.2 Análise de Generalização entre Datasets

Para além da avaliação individual em cada dataset, foi realizada uma análise adicional com o objetivo de estudar a capacidade de generalização dos modelos entre diferentes conjuntos de dados. Esta análise é particularmente relevante porque permite perceber se os padrões aprendidos num determinado dataset se mantêm úteis quando aplicados a dados com características diferentes.

Nesta experiência, os modelos foram treinados num dataset e posteriormente avaliados nos restantes. Desta forma, foi possível observar em que medida o conhecimento adquirido num determinado domínio, por exemplo em dados sintéticos, podia ser transferido para outros datasets, incluindo o dataset TeleAntiFraud. Para simplificar a análise e reduzir o custo computacional, foram considerados apenas os modelos que apresentaram melhor desempenho na fase anterior, nomeadamente a Bi-LSTM e a CNN.

A avaliação da generalização foi realizada com base nas métricas *F1-score* e *recall*. O *F1-score* foi utilizado por combinar *precision* e *recall*, oferecendo uma visão equilibrada do desempenho do modelo. O *recall*, por sua vez, foi considerado particularmente relevante no contexto de deteção de fraude, uma vez que permite avaliar a capacidade do modelo em identificar corretamente exemplos fraudulentos.

Os resultados desta experiência foram representados através de mapas de calor, nos quais as linhas correspondem ao dataset utilizado para treino e as colunas ao dataset utilizado para teste. Desta forma, valores elevados fora da diagonal principal indicam maior capacidade de generalização entre datasets diferentes. Por outro lado, valores elevados na diagonal principal devem ser interpretados apenas como desempenho no próprio domínio de treino, e não como evidência de generalização.

As figuras 5.2 e 5.3 representam os heatmaps com os valores relativos ao modelo Bi-LSTM.

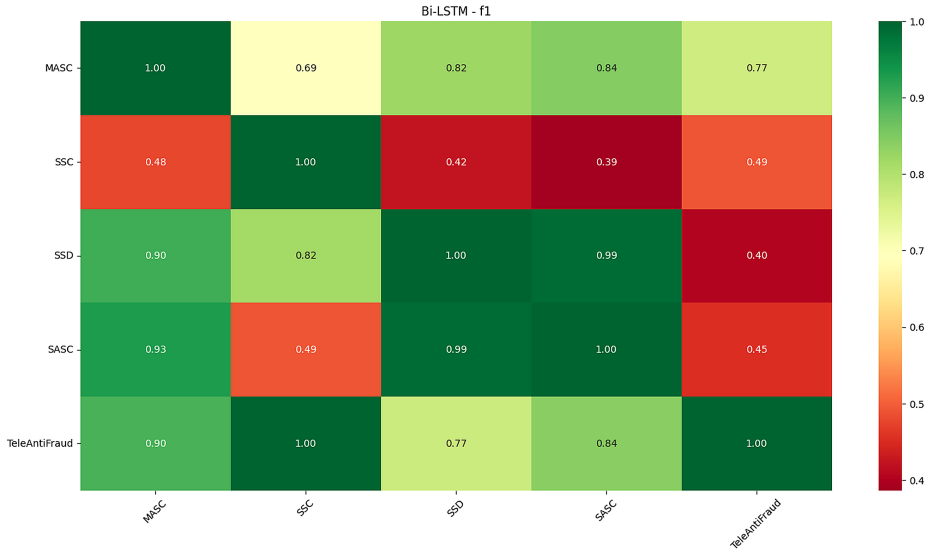


Figura 5.2: Capacidade de generalização Bi-LSTM (*F1-score*).

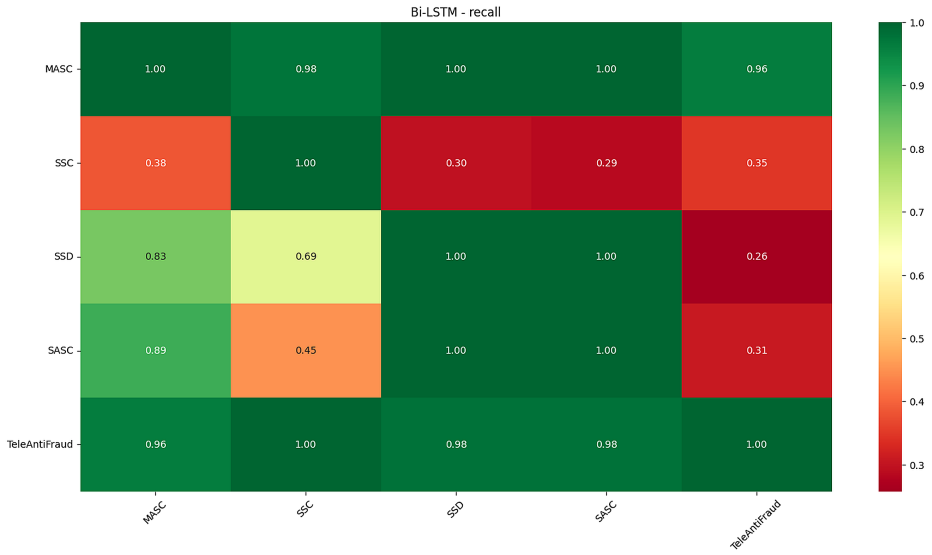


Figura 5.3: Capacidade de generalização Bi-LSTM (*recall*).

No caso do Bi-LSTM, observou-se uma boa capacidade de transferência em alguns cenários, nomeadamente quando o modelo foi treinado no TeleAntiFraud e avaliado nos vários datasets sintéticos. Este resultado sugere que o dataset TeleAntiFraud, por apresentar maior dimensão e maior proximidade ao domínio real, permitiu ao modelo aprender padrões mais gerais e transferíveis para outros conjuntos de dados.

Contudo, a transferência no sentido inverso revelou-se menos consistente. Alguns modelos treinados em datasets sintéticos apresentaram menor capacidade de generalização quando avaliados no TeleAntiFraud, evidenciando diferenças entre os padrões

presentes nos dados sintéticos e os existentes em transcrições mais próximas de um cenário real. Assim, apesar dos resultados elevados obtidos na avaliação individual, os mapas de calor mostram que a Bi-LSTM nem sempre mantém o mesmo desempenho quando aplicada fora do domínio em que foi treinada.

Por sua vez as figuras 5.4 e 5.5 representam os heatmaps que dizem respeito ao modelo CNN.

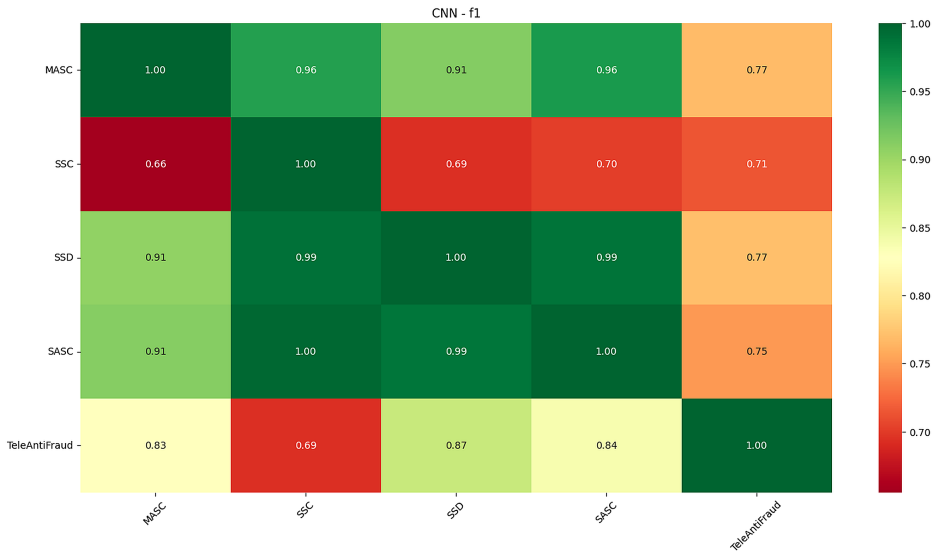


Figura 5.4: Capacidade de generalização CNN (*F1-score*).

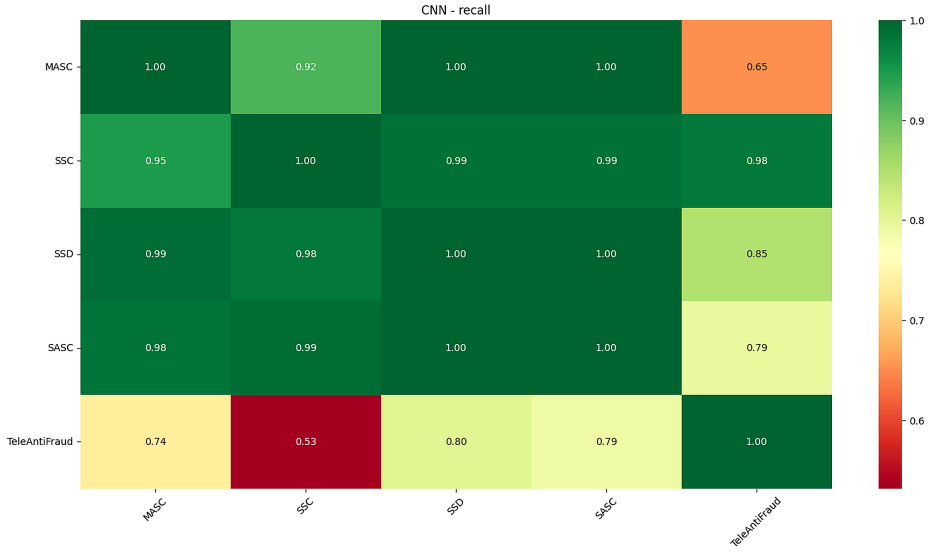


Figura 5.5: Capacidade de generalização CNN (*recall*).

O modelo CNN apresentou um comportamento relativamente estável em várias transferências, especialmente entre datasets sintéticos. Em alguns cenários, este modelo revelou melhor capacidade de transferência para o TeleAntiFraud do que o Bi-LSTM,

sugerindo que os padrões locais capturados por arquiteturas convolucionais podem ser mais robustos entre diferentes conjuntos de dados.

Ainda assim, também neste caso se observaram diferenças relevantes entre a avaliação individual e a avaliação entre datasets. Tal como no Bi-LSTM, os resultados mostram que a capacidade de generalização depende fortemente das características do dataset utilizado para treino e do dataset utilizado para teste. Esta variação reforça a ideia de que datasets sintéticos, embora úteis para validação experimental, não representam necessariamente toda a diversidade linguística presente em transcrições reais.

Os resultados obtidos na aplicação dos modelos treinados no dataset SSC aos outros datasets reforçam a ideia que a capacidade de generalização é fortemente influenciada pelas características dos dados. O dataset SSC é o mais pequeno de todos, apenas 1000 instâncias. Quando se analizam os resultados, as grandes falhas na capacidade de generalização de ambos os modelos concentram-se nos treinados nesse mesmo dataset.

Em síntese, esta análise mostra que os resultados elevados obtidos dentro de cada dataset não garantem, por si só, boa capacidade de generalização. A transferência entre datasets revelou diferenças importantes entre os conjuntos de dados utilizados, reforçando a necessidade de avaliar os modelos não apenas no domínio de treino, mas também em dados com características distintas.

5.3 Discussão dos Resultados

Os resultados obtidos ao longo da fase experimental permitem retirar várias conclusões sobre o comportamento dos modelos de *Deep Learning* aplicados à deteção de fraude em transcrições e diálogos. A primeira observação prende-se com o desempenho muito elevado nos datasets sintéticos. Em vários casos, os modelos alcançaram valores iguais ou próximos de 1.0000 nas principais métricas, o que indica que os padrões presentes nestes conjuntos de dados eram facilmente separáveis pelas arquiteturas avaliadas.

Apesar destes resultados serem positivos do ponto de vista experimental, devem ser interpretados com cautela. A natureza sintética dos dados implica, geralmente, uma menor variabilidade linguística, estruturas de diálogo mais regulares e padrões de fraude mais explícitos. Por esse motivo, os resultados obtidos nestes datasets são úteis para validar a implementação dos modelos e confirmar a capacidade das arquiteturas em aprender padrões relevantes, mas não são suficientes para avaliar a sua aplicabilidade em cenários reais.

O dataset TeleAntiFraud assumiu, por isso, maior importância na análise. Os modelos também apresentaram desempenho muito elevado neste conjunto de dados, destacando-se a Bi-LSTM, a CNN e a GRU. Estes resultados indicam que os modelos foram capazes de capturar padrões relevantes em transcrições mais próximas do domínio real de apli-

cação. Ainda assim, a proximidade entre os resultados de vários modelos sugere que a escolha da arquitetura deve considerar não apenas as métricas finais, mas também fatores como complexidade, custo computacional, estabilidade e capacidade de generalização.

A comparação entre modelos mostrou que arquiteturas mais complexas nem sempre produziram ganhos significativos face a modelos mais simples. O Modelo Base obteve resultados muito competitivos, tanto nos datasets sintéticos como no TeleAntiFraud, demonstrando que uma representação simples pode ser suficiente quando os dados apresentam padrões textuais fortemente discriminativos. Este resultado é relevante porque modelos mais simples tendem a ser mais rápidos de treinar, mais fáceis de interpretar e menos exigentes do ponto de vista computacional.

A análise de generalização reforçou uma conclusão importante: bom desempenho dentro de um dataset não garante necessariamente robustez fora dele. Embora alguns modelos tenham obtido resultados quase perfeitos quando avaliados no mesmo domínio de treino, os mapas de calor mostraram que a transferência entre datasets pode provocar quebras relevantes de desempenho. Este comportamento foi particularmente visível em algumas transferências de datasets sintéticos para o TeleAntiFraud, indicando que nem todos os dados sintéticos capturam adequadamente a variabilidade presente em transcrições mais próximas do real.

Entre os modelos analisados na generalização, a CNN apresentou maior estabilidade em várias transferências, sobretudo por conseguir capturar padrões locais associados à linguagem da fraude. A Bi-LSTM, por outro lado, mostrou bons resultados quando treinada em dados mais representativos, como o TeleAntiFraud, beneficiando da análise contextual bidirecional. Esta diferença sugere que as arquiteturas exploram tipos distintos de informação: enquanto a CNN se foca em padrões locais, a Bi-LSTM procura modelar dependências sequenciais mais amplas.

Outro aspeto relevante é o equilíbrio entre *precision* e *recall*. Num problema de deteção de fraude, um *recall* elevado é importante para reduzir o número de casos fraudulentos não detetados. No entanto, uma *precision* baixa pode levar à sinalização indevida de comunicações legítimas, aumentando falsos positivos. Assim, a escolha do modelo mais adequado dependeria do contexto de utilização: em cenários onde se privilegia a deteção máxima de fraude, poderá ser aceitável tolerar mais falsos positivos; em cenários operacionais mais restritivos, será necessário equilibrar melhor ambas as métricas.

De forma geral, os resultados demonstram que as arquiteturas de *DL* avaliadas são adequadas para a deteção de fraude em dados textuais derivados de comunicações de voz. No entanto, a análise também mostra que a robustez dos modelos depende fortemente da natureza dos dados utilizados no treino e na avaliação. Por esse motivo, a utilização destes modelos em cenários reais exigiria validação adicional com dados mais diversos, representativos e sujeitos ao ruído encontrado em chamadas reais.

5.4 Limitações

Apesar dos resultados obtidos serem bastante positivos, é importante considerar algumas limitações que podem influenciar a interpretação do desempenho dos modelos avaliados. Estas limitações estão relacionadas sobretudo com a natureza dos dados utilizados, com as condições experimentais adotadas e com a aplicabilidade dos modelos em cenários reais.

Uma das principais limitações prende-se com a disponibilidade e qualidade dos dados. A deteção de fraude em chamadas de voz é um domínio particularmente sensível, uma vez que envolve frequentemente transcrições de conversas, dados pessoais e informação potencialmente confidencial. Por esse motivo, a disponibilidade de datasets públicos reais é reduzida, o que limita a possibilidade de treinar e avaliar modelos em dados totalmente representativos de cenários operacionais. Como consequência, parte significativa da avaliação foi realizada com datasets sintéticos, que, embora úteis para validação experimental, não capturam necessariamente toda a variabilidade, ruído e complexidade de chamadas reais.

Os datasets sintéticos utilizados apresentam diálogos mais estruturados e padrões linguísticos mais regulares do que aqueles que seriam expectáveis em comunicações reais. Esta característica contribuiu para resultados muito elevados em várias métricas, mas também limita a interpretação desses valores. Em particular, resultados perfeitos ou próximos de 1.0000 podem refletir a elevada separabilidade dos dados, e não necessariamente uma capacidade equivalente de deteção em ambientes reais, onde os burlões podem utilizar estratégias mais subtis, linguagem menos padronizada ou interações mais ambíguas.

Outra limitação está relacionada com a qualidade das transcrições. O presente trabalho assume que o texto analisado representa adequadamente o conteúdo das chamadas. No entanto, em cenários reais, as transcrições obtidas através de sistemas de reconhecimento automático de fala podem conter erros, omissões, substituições de palavras, falhas na pontuação ou problemas na identificação dos intervenientes. Estes erros podem afetar a representação textual utilizada pelos modelos e, consequentemente, influenciar a classificação final. Além disso, informação presente no sinal áudio original, como tom de voz, pausas, hesitações ou emoção, não foi considerada nesta abordagem.

A estratégia experimental também apresenta algumas limitações. Na avaliação individual, os modelos foram treinados e testados em divisões do mesmo dataset, o que permite medir o desempenho dentro de um determinado domínio, mas não garante, por si só, robustez em dados provenientes de outras fontes. A análise de generalização entre datasets procurou mitigar esta limitação, mas continua dependente dos conjuntos de dados disponíveis e das suas características específicas. Assim, a capacidade de generalização para cenários reais mais diversos deve ser interpretada com cautela.

A interpretabilidade constitui também uma limitação relevante. Embora os modelos de *Deep Learning* possam obter desempenho elevado, nem sempre é evidente quais os padrões linguísticos que conduziram a determinada classificação. Em contextos reais de deteção de fraude, esta limitação pode ser importante, uma vez que sistemas utilizados em ambiente operacional podem necessitar de justificar alertas, apoiar decisões humanas ou permitir auditoria posterior.

Por fim, este trabalho centrou-se exclusivamente na análise textual das transcrições. No entanto, a deteção de fraude em chamadas de voz pode beneficiar da combinação de diferentes tipos de informação, incluindo metadados da chamada, duração, origem, frequência de contactos, histórico do utilizador, características acústicas e sinais comportamentais. A ausência destas fontes adicionais limita a abordagem a uma perspetiva puramente textual, que embora relevante, não representa toda a informação disponível num sistema real de deteção de fraude.

Em suma, apesar dos resultados obtidos demonstrarem o potencial das arquiteturas avaliadas, a sua aplicação prática exigiria validação adicional com dados reais mais diversificados, maior controlo sobre a qualidade das transcrições, avaliação em cenários com maior variabilidade e, idealmente, integração com outras fontes de informação além do texto.

6 Conclusão

O trabalho desenvolvido permitiu verificar que a análise textual de transcrições e diálogos pode constituir uma abordagem viável para a deteção automática de fraude em comunicações de voz. Através da implementação e avaliação de diferentes arquiteturas de *Deep Learning*, foi possível observar que estes modelos conseguem identificar padrões linguísticos associados a comportamentos fraudulentos, especialmente quando os dados apresentam estrutura conversacional e exemplos devidamente rotulados.

Os resultados obtidos mostram que as arquiteturas avaliadas foram capazes de atingir desempenhos elevados na tarefa de classificação, tanto em datasets sintéticos como no dataset TeleAntiFraud. Ainda assim, a análise realizada evidenciou que o desempenho dos modelos depende fortemente da natureza dos dados utilizados. Os resultados muito elevados nos datasets sintéticos demonstram a capacidade dos modelos em aprender padrões presentes nos dados, mas também revelam que conjuntos demasiado estruturados podem facilitar excessivamente a tarefa de classificação. A avaliação no dataset TeleAntiFraud assumiu, por isso, maior relevância, por se aproximar mais do domínio real de aplicação.

Para além da avaliação individual, a análise de generalização entre datasets mostrou que bons resultados dentro de um determinado conjunto de dados não garantem necessariamente robustez quando o modelo é aplicado a dados com características diferentes. Esta observação é particularmente importante no contexto da deteção de fraude, uma vez que os padrões linguísticos utilizados por atacantes podem variar consoante o tipo de chamada, o contexto e a origem dos dados.

Apesar dos resultados positivos, o trabalho apresenta algumas limitações. A principal está relacionada com a disponibilidade e qualidade dos dados. A utilização de datasets sintéticos foi útil para validação experimental, mas estes não capturam totalmente a complexidade de chamadas reais. Além disso, a abordagem seguida baseou-se exclusivamente em texto, não considerando informação acústica ou metadados da chamada. A qualidade das transcrições constitui também um fator crítico, uma vez que erros de reconhecimento automático de fala podem influenciar o desempenho dos modelos.

Como trabalho futuro, seria relevante avaliar as arquiteturas implementadas em datasets reais mais diversificados, incluindo transcrições com maior variabilidade linguística e ruído semelhante ao encontrado em cenários operacionais. A integração de outras fontes de informação, como metadados das chamadas, características acústicas ou histórico de interações, poderia também contribuir para modelos mais robustos. Seria

ainda pertinente explorar a capacidade de deteção em tempo real, considerando aspetos como latência, custo computacional e aplicabilidade em ambientes operacionais.

Em suma, os objetivos definidos foram cumpridos, demonstrando o potencial de arquiteturas de *Deep Learning* na deteção de fraude em transcrições de chamadas. Para além dos resultados obtidos, o projeto permitiu consolidar competências em processamento de linguagem natural, preparação de dados, implementação de modelos neuronais e avaliação experimental. Ainda assim, a aplicação prática destas abordagens exigiria validação adicional com dados reais, diversos e representativos.

Referências bibliográficas

[1] G. Yadav, Deepak, H. Sharma, D. Sharma, and A. K. Rai, "A study on deep learning based anomaly detection technique in natural language processing textual data," in *2024 2nd International Conference on Advances in Computation, Communication and Information Technology (ICAICCIT)*, vol. 1, 2024, pp. 869–873. [Online]. Available: https://ieeexplore.ieee.org/document/10912228

[2] A. K. Veldurthi, "The role of ai and machine learning in fraud detection for financial services," *Journal of Computer Science and Technology Studies*, 2025.

[3] B. A. Yehya and N. Salhab, "Telecommunications fraud machine learning-based detection," in *2023 4th International Conference on Data Analytics for Business and Industry (ICDABI)*, 2023, pp. 656–661. [Online]. Available: https://ieeexplore.ieee.org/document/10629612

[4] E. Edozie, A. N. Shuaibu, B. O. Sadiq, and U. K. John, "Artificial intelligence advances in anomaly detection for telecom networks," *Artificial Intelligence Review*, vol. 58, 2025. [Online]. Available: https://link.springer.com/article/10.1007/s10462-025-11108-x

[5] H. Huo, "Telecom fraud detection based on deep learning," in *2024 6th International Academic Exchange Conference on Science and Technology Innovation (IAECST)*, 2024, pp. 1132–1137. [Online]. Available: https://ieeexplore.ieee.org/document/11117868

[6] Z. Rojan, "Financial fraud detection based on machine and deep learning: A review," *Indonesian Journal of Computer Science*, 2024. [Online]. Available: https://www.ijcs.net/ijcs/index.php/ijcs/article/view/4059

[7] A. Ali, S. Abd Razak, S. H. Othman, T. A. E. Eisa, A. Al-Dhaqm, M. Nasser, T. Elhassan, H. Elshafie, and A. Saif, "Financial fraud detection based on machine learning: A systematic literature review," *Applied Sciences*, vol. 12, no. 19, 2022. [Online]. Available: https://www.mdpi.com/2076-3417/12/19/9637

[8] T. K. Team, "O que é engenharia social?" 2026. [Online]. Available: https://www.kaspersky.com.br/resource-center/definitions/what-is-social-engineering

[9] S. Trust and S. Team, "Subscription fraud: Inside the rising threat of hidden scams," Aug 2025. [Online]. Available: https://sift.com/blog/how-to-spot-and-stop-subscription-fraud/

[10] R. O'Connor, "How does roaming fraud affect mobile subscribers?" *Juniper Research*, 2023. [Online]. Available: https://www.juniperresearch.com/resources/blog/how-does-roaming-fraud-affect-mobile-subscribers/

[11] T. P. Team, "Vishing statistics 2026," may 2026. [Online]. Available: https://programs.com/resources/voice-phishing-stats/

[12] A. Ravi, M. Msahli, H. Qiu, G. Memmi, A. Bifet, and M. Qiu, "Wangiri fraud: Pattern analysis and machine-learning-based detection," *IEEE Internet of Things Journal*, vol. 10, no. 8, pp. 6794–6802, 2023. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/9772071

[13] E. Rescorla and J. Peterson, "Secure Telephone Identity Revisited (STIR) Out-of-Band Architecture and Use Cases," RFC 8816, Feb. 2021. [Online]. Available: https://www.rfc-editor.org/info/rfc8816

[14] Alliance for Telecommunications Industry Solutions, "Signature-based handling of asserted information using tokens (shaken)," 2021, aTIS Standard 1000074. [Online]. Available: https://atis.org/resources/signature-based-handling-of-asserted-information-using-tokens-shaken-atis-1000074-e/

[15] X. Li, "Research on developing a telecom fraud detection model based on logistic regression," in *2025 IEEE 3rd International Conference on Image Processing and Computer Applications (ICIPCA)*, 2025, pp. 11–16. [Online]. Available: https://ieeexplore.ieee.org/document/11138523

[16] P. K. Kumar, S. Ray, L. Kumarasankaralingam, A. Ramamoorthy, P. Kumar, and A. Dutta, "Detecting fraud calls vis-à-vis natural language processing," in *2024 2nd International Conference on Advancement in Computation Computer Technologies (InCACCT)*, 2024, pp. 457–462. [Online]. Available: https://ieeexplore.ieee.org/document/10551082

[17] I. H. Sarker, "Machine learning: Algorithms, real-world applications and research directions," *Sn Computer Science*, vol. 2, 2021.

[18] A. Natarajan, A. Kannan, V. Belagali, V. N. Pai, R. Shettar, and P. Ghuli, "Spam detection over call transcript using deep learning," in *Proceedings of the Future Technologies Conference (FTC) 2021, Volume 2*, K. Arai, Ed. Cham: Springer International Publishing, 2022, pp. 138–150. [Online]. Available: https://link.springer.com/chapter/10.1007/978-3-030-89880-9_10

[19] N. Kale, S. Kochrekar, R. Mote, and S. Dholay, "Classification of fraud calls by intent analysis of call transcripts," in *2021 12th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, 2021, pp. 1–6. [Online]. Available: https://ieeexplore.ieee.org/document/9579632

[20] B. Hong, T. Connie, and M. K. Ong Goh, "Scam calls detection using machine

learning approaches," in *2023 11th International Conference on Information and Communication Technology (ICoICT)*, 2023, pp. 442–447. [Online]. Available: https://ieeexplore.ieee.org/document/10262695

[21] S. Arifin, A. Wijaya, R. Nariswari, I. Yudistira, S. Suwarno, F. Faisal, and D. Wihardini, "Long short-term memory (lstm): Trends and future research potential," *International Journal of Emerging Technology and Advanced Engineering*, 2023.

[22] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," 2013. [Online]. Available: https://arxiv.org/abs/1301.3781

[23] J. Pennington, R. Socher, and C. Manning, "GloVe: Global vectors for word representation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, A. Moschitti, B. Pang, and W. Daelemans, Eds. Doha, Qatar: Association for Computational Linguistics, Oct. 2014, pp. 1532–1543. [Online]. Available: https://aclanthology.org/D14-1162/

[24] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," 2023. [Online]. Available: https://arxiv.org/abs/1706.03762

[25] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," 2019. [Online]. Available: https://arxiv.org/abs/1810.04805

[26] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, "Roberta: A robustly optimized bert pretraining approach," 2019. [Online]. Available: https://arxiv.org/abs/1907.11692

[27] Python Software Foundation, "Python 3 Documentation," https://docs.python.org/3/, 2026.

[28] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant, "Array programming with NumPy," *Nature*, vol. 585, no. 7825, pp. 357–362, 2020. [Online]. Available: https://doi.org/10.1038/s41586-020-2649-2

[29] NumPy Developers, "NumPy Documentation," https://numpy.org/doc/, 2026.

[30] W. McKinney, "Data structures for statistical computing in python," pp. 56–61, 2010.

[31] The pandas development team, "pandas Documentation," https://pandas.pydata.org/docs/, 2026.

[32] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://jmlr.org/papers/v12/pedregosa11a.html

[33] scikit-learn developers, "scikit-learn Documentation," https://scikit-learn.org/stable/, 2026.

[34] TensorFlow Developers, "TensorFlow Documentation," https://www.tensorflow.org/, 2026.

[35] Keras Team, "Keras 3 API Documentation," https://keras.io/api/, 2026.

[36] J. D. Hunter, "Matplotlib: A 2d graphics environment," *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007. [Online]. Available: https://doi.org/10.1109/MCSE.2007.55

[37] Matplotlib Development Team, "Matplotlib Documentation," https://matplotlib.org/stable/, 2026.

[38] M. L. Waskom, "seaborn: statistical data visualization," *Journal of Open Source Software*, vol. 6, no. 60, p. 3021, 2021. [Online]. Available: https://doi.org/10.21105/joss.03021

[39] Seaborn Developers, "seaborn Documentation," https://seaborn.pydata.org/, 2026.

Anexos

Anexo A - Proposta de Projeto

Departamento de Engenharia Informática e de Sistemas
Licenciaturas em Engenharia Informática (LEI e LEI-PL)

Proposta de Projeto

Ano Letivo de 2025/2026
2º Semestre

Deteção de Fraude em Comunicações de Voz usando técnicas de Machine Learning

SUMÁRIO

Este projeto propõe a aplicação de metodologias de Machine Learning na deteção automática de SPAM e fraude em chamadas de voz, um problema crescente no contexto das comunicações digitais. O objetivo principal é desenvolver modelos inteligentes capazes de identificar padrões suspeitos, recorrendo à análise de diversas características das chamadas.
O projeto prevê a utilização de conjuntos de dados simulados e será realizado em estreita colaboração com a WIT Software, uma das principais empresas portuguesas especializada no desenvolvimento de aplicações e serviços para operadores móveis e empresas de telecomunicações.
A realização do projeto prevê a atribuição de uma bolsa de iniciação à investigação. Será realizado um processo de seleção e seriação para todos os candidatos interessados no tema.

ESTAGIÁRIO *(indicar o destinatário da proposta se já estiver definido)*

Número de aluno	Click or tap here to enter text.
Nome completo	Click or tap here to enter text.

RAMO *(indicar o(s) ramo(s) em que se enquadra a proposta)*

☒ Desenvolvimento de Aplicações
☐ Redes e Administração de Sistemas
☒ Sistemas de Informação

ENTREVISTA/PROCESSO DE SELEÇÃO

(informar se o candidato indicado pelo DEIS-ISEC será submetido a uma entrevista ou outro tipo de processo de seleção antes da sua admissão efetiva. Deverá ser tida em consideração a natureza das atividades a desenvolver, enquadradas no âmbito de um projeto ou estágio curricular)

☐ Não
☒ Entrevista Click or tap here to enter text.
☒ Outro, especificar: Análise curricular

1. ÂMBITO

As abordagens atuais para lidar com este problema são maioritariamente baseadas em regras heurísticas e listas negras, revelando limitações em termos de precisão, escalabilidade e capacidade de adaptação a novos padrões de ataque. Este projeto pretende analisar a viabilidade de utilizar modelos avançados de Machine Learning, com potencial para identificar comportamentos anómalos com maior robustez, reduzindo falsos positivos/negativos. Espera-se que o estudo contribua para uma melhor compreensão sobre como aumentar a eficácia e robustez dos sistemas de segurança em telecomunicações.

O projeto é realizado no âmbito de um financiamento do programa COMPETE 2030, em parceria com a WIT Software, envolvendo uma equipa de estudantes e docentes do ISEC. Os trabalhos podem ser parcialmente realizados nas instalações da empresa, com coorientação dos seus colaboradores.

2. OBJETIVOS

O presente projeto/estágio pretende atingir os seguintes objetivos genéricos:

- Compreensão dos mecanismos de fraude em chamadas de voz
- Estudo das técnicas utilizadas na deteção de fraude em chamadas de voz
- Implementação e teste de métodos de machine learning para deteção de fraude em chamadas de voz

3. PROGRAMA DE TRABALHOS

O projeto/estágio consistirá nas seguintes atividades e respetivas tarefas: *(a adaptar em função do projeto/estágio)*

T1. *Estado da Arte*

Revisão de literatura e abordagens na área de deteção de fraude em chamadas de voz

T2. *Identificação de Recursos*

Identificação de conjuntos de dados e de métodos inteligentes que possam ser usados na deteção de fraude em chamadas de voz.

T3. *Proposta de Abordagens*

Desenvolvimento de métodos inteligentes para deteção de fraude em chamadas de voz.

T4. *Validação*

Testes em dados simulados para avaliação da eficácia comparativa das abordagens desenvolvidas.

T5. *Documentação*

Elaboração do relatório final e preparação para a defesa.

4. CALENDARIZAÇÃO DAS TAREFAS

O plano de escalonamento das tarefas é apresentado em seguida: *(a adaptar em função do projeto/estágio)*

Tarefas		Meses											
		N		N+1		N+2		N+3		N+4		N+5	
T1	*Estado da Arte*												
T2	*Identificação de Recursos*												
T3	*Proposta de Abordagens*												
T4	*Validação*												
T5	*Documentação*												

5. EMPRESA, LOCAL, HORÁRIO DE TRABALHO E CONDIÇÕES OFERECIDAS

Empresa	WIT Software
Morada	Centro de Empresas de Taveiro
Local do Estágio	☒ Instalações da empresa ☒ Remoto ☒ Outro, ISEC
Horário trabalho	Click or tap here to enter text.
Condições oferecidas	Prevista a atribuição de uma bolsa de iniciação à investigação. Click or tap here to enter text.

6. TECNOLOGIAS ENVOLVIDAS

Bibliotecas Python para armazenamento, gestão, manipulação e visualização de dados: Pandas, NumPy, MatplotLib.
Bibliotecas Python para análise inteligente de dados: Scikit-learn, Keras, TensorFlow, PyTorch.

7. METODOLOGIA

Serão realizadas reuniões semanais para discutir o progresso do trabalho com os orientadores.
Serão realizadas reuniões e apresentações regulares com a WIT Software, a empresa parceira do projeto.
Toda a bibliografia, documentação e código desenvolvidos serão partilhados através de plataformas na *cloud*.

8. ORIENTAÇÃO

Orientador da Entidade de acolhimento:

Nome	Click or tap here to enter text.
Email	Click or tap here to enter text.
Cargo	Click or tap here to enter text.
Formação	Choose an item.

Orientador do DEIS-ISEC: *(caso já esteja definido)*

Nome	Simão Paredes, Francisco Pereira
Email	Click or tap here to enter text.



Instituto Superior
de Engenharia
Politécnico de Coimbra